dns_achados

Rafilx

2022-04-14

R Markdown

```
##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
##     filter, lag

## The following objects are masked from 'package:base':
##
##     intersect, setdiff, setequal, union

## Loading required package: viridisLite

##
## Attaching package: 'lubridate'

## The following objects are masked from 'package:base':
##
##     date, intersect, setdiff, union
```

- Busca os dados no banco com o parse do DNS ja realizado, então temos:
  - qname que é o domínio
  - qtype tipo da query
  - query_id ID da transação definido pelo atacante
  - year_period ano e trimestre em que ocorreu o ataque exemplo "20212" o ataque ocorreu no segundo trimestre do 2021

```
db <- dbConnect(RSQLite::SQLite(), dbname="./dnstor_statistics_dns.sqlite")

data_unfetch <-dbSendQuery(db, "
  SELECT *, CAST(CAST(year AS text) || CAST(period AS text) as integer) as year_period
    FROM DNS_ANALYSIS
        JOIN DNS_ANALYSIS_QUESTION
          ON DNS_ANALYSIS.id = DNS_ANALYSIS_QUESTION.dns_analysis_id
     WHERE QTYPE != 0
")
data <- fetch(data_unfetch)
```

```
dns_data_unfetch <- dbSendQuery(db, "
  SELECT count(*) as countGrouped, year, period, CAST(CAST(year AS text) || CAST(period AS text) as int
    FROM DNS_ANALYSIS
    JOIN DNS_ANALYSIS_QUESTION
      ON DNS_ANALYSIS.id = DNS_ANALYSIS_QUESTION.dns_analysis_id
   WHERE QTYPE != 0
GROUP BY year_period, year, period, qname, qtype
ORDER BY quantity DESC;
")
```

```
## Warning: Closing open result set, pending rows
```

```
dns_data_fetched <- fetch(dns_data_unfetch)

dns_data_overlap_unfetch <- dbSendQuery(db, "
   SELECT *
     FROM TB_DATE_OVERLAP_QUERYID
 ORDER BY amount_overlap;
")
```

```
## Warning: Closing open result set, pending rows
```

```
dns_data_overlap_fetched <- fetch(dns_data_overlap_unfetch)

dbDisconnect(db)
```

```
## Warning in connection_release(conn@ptr): There are 1 result in use. The
## connection will be released when they are closed
```

- Primeiro separa todos os registros por trimestre

```
data_split_year_period = data %>%
  group_split(year_period)
```

- Gerando um total de 6 trimestres

```
N=10

period_query_id = data.frame()
for (i in c(1:length(data_split_year_period))) {
  query_id_frequency = data_split_year_period[[i]] %>%
    count(query_id)

  query_id_frequency['year_period'] = data_split_year_period[[i]]$year_period[1]

  period_query_id = rbind(period_query_id, head(query_id_frequency[order(-query_id_frequency$n),], N) )
}
```

Os 10 query_id mais utilizados divididos por período e ordenados pela frequência em que apareceram no período

```
period_query_id %>%
  group_split(year_period)
```

```
## <list_of<
##   tbl_df<
##     query_id   : integer
##     n          : integer
##     year_period: integer
##   >
## >[6]>
## [[1]]
## # A tibble: 10 x 3
##    query_id     n year_period
##       <int> <int>       <int>
##  1    17767  1917       20204
##  2    16049  1060       20204
##  3    56064  1049       20204
##  4    63710   782       20204
##  5    59797   741       20204
##  6    63374   729       20204
##  7    59378   723       20204
##  8    31694   718       20204
##  9    13304   715       20204
## 10    46512   707       20204
##
## [[2]]
## # A tibble: 10 x 3
##    query_id     n year_period
##       <int> <int>       <int>
##  1    17767 67047       20211
##  2    28940   418       20211
##  3    13551   318       20211
##  4    50265   305       20211
##  5    19592   277       20211
##  6    45810   214       20211
##  7    57166   197       20211
##  8    43855   168       20211
##  9    56643   125       20211
## 10    56686   124       20211
##
## [[3]]
## # A tibble: 10 x 3
##    query_id     n year_period
##       <int> <int>       <int>
##  1    26566  5090       20212
##  2    17767  3748       20212
##  3    13551   348       20212
##  4    50265   118       20212
##  5    37845    81       20212
##  6        1    65       20212
```

```
##  7    36379    60       20212
##  8    45810    59       20212
##  9     1525    47       20212
## 10    40074    38       20212
##
## [[4]]
## # A tibble: 10 x 3
##    query_id     n year_period
##       <int> <int>       <int>
##  1        1  6859       20213
##  2    17767  5838       20213
##  3    13551   783       20213
##  4       27   403       20213
##  5    59252   253       20213
##  6    60765   220       20213
##  7    13143   212       20213
##  8    53342   157       20213
##  9    65372   102       20213
## 10    14262   100       20213
##
## [[5]]
## # A tibble: 10 x 3
##    query_id     n year_period
##       <int> <int>       <int>
##  1    26566 29963       20214
##  2    17767  8479       20214
##  3        1   677       20214
##  4    13551   566       20214
##  5       27   102       20214
##  6    28826    70       20214
##  7    36609    69       20214
##  8     3803    60       20214
##  9    47132    58       20214
## 10    50265    51       20214
##
## [[6]]
## # A tibble: 10 x 3
##    query_id     n year_period
##       <int> <int>       <int>
##  1    26566  5876       20221
##  2    17767   895       20221
##  3    13551   124       20221
##  4        1   120       20221
##  5    64206    63       20221
##  6    28826    41       20221
##  7       27    29       20221
##  8    14602    19       20221
##  9    50293    15       20221
## 10        6    12       20221
```

- Dessa forma é possível observar que o mesmo query_id é utilizado várias vezes durante o mesmo trimestre, como no primeiro trimestre de 2021 que o query_id 17767 foi utilizado em 67047 ataques

Os 10 query_id mais utilizados

```
data %>%
  count(query_id) %>%
  arrange(desc(n)) %>%
  head(N)
```

```
##    query_id     n
## 1     17767 87924
## 2     26566 40940
## 3         1  7803
## 4     13551  2347
## 5     16049  1062
## 6     56064  1054
## 7     63710   785
## 8     59797   746
## 9     63374   738
## 10    46512   728
```

Os 10 query_id mais utilizados em cada período ordenados pela frequência em que apareceram levando em consideração todos os períodos

```
period_query_id %>%
  arrange(desc(n)) %>%
  head(N)
```

```
## # A tibble: 10 x 3
##    query_id     n year_period
##       <int> <int>       <int>
##  1    17767 67047       20211
##  2    26566 29963       20214
##  3    17767  8479       20214
##  4        1  6859       20213
##  5    26566  5876       20221
##  6    17767  5838       20213
##  7    26566  5090       20212
##  8    17767  3748       20212
##  9    17767  1917       20204
## 10    16049  1060       20204
```

Os query_id que apareceram com maior frequência entre os top 10 em todos os períodos

- Caso o query_id 13213 fosse top 1 em 20204 e top 3 em 20211 e não aparecer em mais nenhum outro período seu "n" seria 2

```
period_query_id %>%
  count(query_id) %>%
  arrange(desc(n)) %>%
  filter(n > 1)
```

```
## # A tibble: 8 x 2
##   query_id     n
##      <int> <int>
## 1    17767     6
## 2    13551     5
## 3        1     4
## 4       27     3
## 5    26566     3
## 6    50265     3
## 7    28826     2
## 8    45810     2
```

- Isso apresenta que um mesmo query_id esteve no top 10 em "n" trimestres diferentes, o que levanta a possibilidade de que atacantes diferentes possam estar utilizando a mesma ferramenta para realizar ataques

Dados agrupados por qname, query_id, período e qtype

```
period_query_id_qname = data.frame()
for (i in c(1:length(data_split_year_period))) {
  query_id_qname_frequency = data_split_year_period[[i]] %>%
    count(qname, qtype, query_id, year_period, sort = TRUE) %>%
    filter(n > 1)

  period_query_id_qname = rbind(period_query_id_qname, head(query_id_qname_frequency, N) )
}
```

Os 10 query_id, qname, qtype mais utilizados divididos por período e ordenados pela frequência em que apareceram no período

```
period_query_id_qname %>%
  group_split(year_period)
```

```
## <list_of<
##   tbl_df<
##     qname      : character
##     qtype      : character
##     query_id   : integer
##     year_period: integer
##     n          : integer
##   >
## >[6]>
## [[1]]
## # A tibble: 10 x 5
##    qname    qtype query_id year_period     n
##    <chr>    <chr>    <int>       <int> <int>
##  1 isc.org. ANY      17767       20204  1141
##  2 irs.gov. ANY      16049       20204  1060
##  3 irs.gov. ANY      56064       20204  1049
##  4 irs.gov. ANY      63710       20204   782
```

```
##  5 sl.      ANY      17767       20204   764
##  6 irs.gov. ANY      59797       20204   741
##  7 irs.gov. ANY      63374       20204   728
##  8 irs.gov. ANY      59378       20204   721
##  9 irs.gov. ANY      31694       20204   718
## 10 irs.gov. ANY      13304       20204   713
##
## [[2]]
## # A tibble: 10 x 5
##    qname          qtype query_id year_period     n
##    <chr>          <chr>    <int>       <int> <int>
##  1 isc.org.       ANY      17767       20211 56753
##  2 sl.            ANY      17767       20211 10260
##  3 .              ANY      28940       20211   417
##  4 VERSION.BIND.  TXT      13551       20211   314
##  5 .              ANY      19592       20211   273
##  6 .              ANY      57166       20211   196
##  7 .              ANY      43855       20211   164
##  8 fe18.ru.       ANY      56643       20211   124
##  9 fe18.ru.       ANY      56686       20211   122
## 10 .              ANY      10000       20211   117
##
## [[3]]
## # A tibble: 10 x 5
##    qname                                       qtype query_id year_period     n
##    <chr>                                       <chr>    <int>       <int> <int>
##  1 peacecorps.gov.                             ANY      26566       20212  5090
##  2 sl.                                         ANY      17767       20212  3739
##  3 VERSION.BIND.                               TXT      13551       20212   346
##  4 213.1.168.192.in-addr.arpa.                 PTR      37845       20212    80
##  5 com.                                        ANY       1525       20212    46
##  6 67b.org.                                    AAAA     40074       20212    38
##  7 hcc.nl.                                     ANY          3       20212    33
##  8 version.bind.                               TXT          6       20212    30
##  9 pizzaseo.com.                               RRSIG        1       20212    29
## 10 200-19-107-238.measurebr.xiaofengtest.com. A        50265       20212    24
##
## [[4]]
## # A tibble: 10 x 5
##    qname          qtype query_id year_period     n
##    <chr>          <chr>    <int>       <int> <int>
##  1 pizzaseo.com. RRSIG        1       20213  6236
##  2 sl.            ANY      17767       20213  5764
##  3 VERSION.BIND.  TXT      13551       20213   783
##  4 pizzaseo.com.  ANY         27       20213   403
##  5 .              ANY      59252       20213   252
##  6 .              ANY      60765       20213   219
##  7 .              ANY      13143       20213   212
##  8 .              ANY      53342       20213   155
##  9 .              ANY      65372       20213   102
## 10 .              ANY      14262       20213   100
##
## [[5]]
## # A tibble: 10 x 5
```

```
##    qname             qtype query_id year_period     n
##    <chr>             <chr>    <int>       <int> <int>
##  1 peacecorps.gov.   ANY      26566       20214 29963
##  2 sl.               ANY      17767       20214  8433
##  3 VERSION.BIND.     TXT      13551       20214   564
##  4 pizzaseo.com.     ANY         27       20214   101
##  5 pizzaseo.com.     RRSIG        1       20214    97
##  6 .                 ANY      36609       20214    69
##  7 ip.parrotdns.com. A        28826       20214    68
##  8 .                 ANY      47132       20214    58
##  9 .                 ANY       3803       20214    57
## 10 .                 ANY      20986       20214    47
##
## [[6]]
## # A tibble: 10 x 5
##    qname                     qtype query_id year_period     n
##    <chr>                     <chr>    <int>       <int> <int>
##  1 peacecorps.gov.           ANY      26566       20221  5876
##  2 sl.                       ANY      17767       20221   841
##  3 VERSION.BIND.             TXT      13551       20221   122
##  4 ip.parrotdns.com.         A        28826       20221    41
##  5 dnsscan.shadowserver.org. A        64206       20221    33
##  6 version.bind.             TXT      64206       20221    30
##  7 pizzaseo.com.             ANY         27       20221    29
##  8 isc.org.                  ANY      17767       20221    24
##  9 pizzaseo.com.             RRSIG        1       20221    21
## 10 clients1.google.com.      A        14602       20221    19
```

- Ao observar esses registros, é possível verificar que alguns deles se repetem durante o tempo utilizando o mesmo qname, qtype e query_id, e que possívelmente não fizeram nenhuma alteração na ferramenta de ataque durante o período observado que iniciou no ultimo trimestre de 2020 até o primeiro trimestre de 2022.

Os query_id que apareceram com maior frequência entre os top 10 em todos os períodos, agrupados por qname e qtype

- Caso o query_id 13213 de qname = "isc.org." e qtype = "ANY" fosse top 1 em 20204 e top 3 em 20211 e não aparecer em mais nenhum outro período seu "n" seria 2

```
top_queryid_qname = period_query_id_qname %>%
  count(query_id, qtype, qname) %>%
  arrange(desc(n)) %>%
  filter(n > 1)

top_queryid_qname
```

```
## # A tibble: 7 x 4
##   query_id qtype qname                n
##      <int> <chr> <chr>              <int>
## 1    17767 ANY   sl.                    6
## 2    13551 TXT   VERSION.BIND.          5
## 3        1 RRSIG pizzaseo.com.          4
```

```
## 4       27 ANY   pizzaseo.com.         3
## 5    17767 ANY   isc.org.              3
## 6    26566 ANY   peacecorps.gov.       3
## 7    28826 A     ip.parrotdns.com.     2
```

- O ataque do tipo ANY de qname "sl." e query_id "17767" apareceu no top 10 6x, ou seja em todo trimestre esse foi um dos ataques mais realizados que passaram pelos honeypots

Top 10 consultas que receberam a maior quantidade de requisições por períodos

```
dns_data.year_period.ungrouped <- group_split(dns_data_fetched, year_period)

dns_data.topNconsultas <- head(dns_data.year_period.ungrouped[[1]], N)
dns_data.year_period.ungrouped.len = length(dns_data.year_period.ungrouped)

dns_columns = c('year_period', 'qtype', 'quantity', 'qname')
select(dns_data.topNconsultas, dns_columns)
```

```
## Note: Using an external vector in selections is ambiguous.
## i Use ‘all_of(dns_columns)‘ instead of ‘dns_columns‘ to silence this message.
## i See <https://tidyselect.r-lib.org/reference/faq-external-vector.html>.
## This message is displayed once per session.

## # A tibble: 10 x 4
##    year_period qtype quantity qname
##          <int> <chr>    <int> <chr>
##  1       20204 ANY   19005578 peacecorps.gov.
##  2       20204 ANY     816242 lavrov.in.
##  3       20204 ANY     779892 sl.
##  4       20204 ANY     652325 irs.gov.
##  5       20204 ANY     569411 fe18.ru.
##  6       20204 ANY      12296 .
##  7       20204 ANY      10248 isc.org.
##  8       20204 A         8467 20200328132334-cq9bm.ldd.sohu.com.
##  9       20204 RRSIG     6176 jp.
## 10       20204 A         4953 500940734da64dde863b257c9c12c03d.apigw.ap-southea~
```

```
select(head(dns_data.year_period.ungrouped[[2]], N), dns_columns)
```

```
## # A tibble: 10 x 4
##    year_period qtype quantity qname
##          <int> <chr>    <int> <chr>
##  1       20211 ANY   32698124 peacecorps.gov.
##  2       20211 ANY    3032399 sl.
##  3       20211 ANY    2418859 isc.org.
##  4       20211 ANY     941083 fe18.ru.
##  5       20211 ANY     463904 wzb.eu.
##  6       20211 ANY     132970 .
##  7       20211 A        20998 mirrorlist.centos.org.
##  8       20211 A        10698 hotspot.accesscam.org.
##  9       20211 MX        8014 pwad.gov.ae.
## 10       20211 A         3882 theguardian.webredirect.org.
```

```
select(head(dns_data.year_period.ungrouped[[3]], N), dns_columns)
```

```
## # A tibble: 10 x 4
##    year_period qtype quantity qname
##          <int> <chr>    <int> <chr>
##  1       20212 ANY   13183512 peacecorps.gov.
##  2       20212 ANY    1337802 sl.
##  3       20212 ANY     534815 irs.gov.
##  4       20212 ANY     220674 isc.org.
##  5       20212 ANY     124579 fe18.ru.
##  6       20212 ANY      90999 .
##  7       20212 MX       21895 dpc.ae.
##  8       20212 ANY      11229 hcc.nl.
##  9       20212 A        10965 dji.gov.ae.
## 10       20212 A         9144 emaratalyoum.com.
```

```
select(head(dns_data.year_period.ungrouped[[4]], N), dns_columns)
```

```
## # A tibble: 10 x 4
##    year_period qtype quantity qname
##          <int> <chr>    <int> <chr>
##  1       20213 RRSIG   324789 pizzaseo.com.
##  2       20213 ANY     178363 sl.
##  3       20213 ANY     165932 .
##  4       20213 A         5925 www.ac.my.blastodermic-swimmable.info.
##  5       20213 A         5291 tmall.com.
##  6       20213 A         4848 www.ac.my.superability-kooka.info.
##  7       20213 A         4655 2015annualreport.bloomberg.org.
##  8       20213 A         2794 lpnkuearwljpqwbwz.tmall.com.
##  9       20213 MX        1915 rt.com.
## 10       20213 MX        1888 nawahprogram.ae.
```

```
select(head(dns_data.year_period.ungrouped[[5]], N), dns_columns)
```

```
## # A tibble: 10 x 4
##    year_period qtype quantity qname
##          <int> <chr>    <int> <chr>
##  1       20214 ANY    4844082 peacecorps.gov.
##  2       20214 ANY     620249 sl.
##  3       20214 A        19541 www.ac.my.blastodermic-swimmable.info.
##  4       20214 A        17848 www.ac.my.superability-kooka.info.
##  5       20214 A        13595 www.ndnslab.com.
##  6       20214 ANY      11073 .
##  7       20214 RRSIG     8499 pizzaseo.com.
##  8       20214 MX        6670 nih.gov.
##  9       20214 A         5932 2015annualreport.bloomberg.org.
## 10       20214 MX        4680 nawahprogram.ae.
```

```
select(head(dns_data.year_period.ungrouped[[6]], N), dns_columns)
```

```
## # A tibble: 10 x 4
```

```
##    year_period qtype quantity qname
##          <int> <chr>    <int> <chr>
##  1       20221 ANY    2614699 peacecorps.gov.
##  2       20221 A        21200 admin.asry.net.
##  3       20221 ANY      19737 sl.
##  4       20221 A        18629 www.ndnslab.com.
##  5       20221 A        11635 ftp.ebisb.com.
##  6       20221 MX        7821 bankfab.com.
##  7       20221 A         6091 vpn.qatarsteel.com.qa.
##  8       20221 MX        6025 zayed.org.ae.
##  9       20221 A         5766 moi.gov.kw.
## 10       20221 MX        5077 mopa.ae.
```

```
for (i in c(2:dns_data.year_period.ungrouped.len)) {
  dns_data.topNconsultas <- rbind(dns_data.topNconsultas, head(dns_data.year_period.ungrouped[[i]], N))
}
```

```
## ------------ Quantos ataques com cada tipo de qtype foi utilizado, por trimestre ? ------------
#dns_data_fetched

dns_data_fetched.quarter_type_quantity = select(dns_data_fetched, c('year_period', 'qtype', 'quantity'))

dns_data_fetched.sum_attacks_quarterly = dns_data_fetched.quarter_type_quantity %>%
  group_by(qtype, year_period) %>%
  summarise(quantity = sum(quantity))
```

```
## `summarise()` has grouped output by 'qtype'. You can override using the
## `.groups` argument.
```

```
#dns_data_fetched.sum_attacks_quarterly %>%
#  mutate(year_period=as.factor(year_period)) %>%
#  ggplot(aes(x = year_period, y = quantity, color = qtype)) +
#  geom_line()

#ggplot(data = dns_data_fetched.sum_attacks_quarterly, aes(x = year_period, y = quantity)) +
#    geom_line() +
#    facet_wrap(facets = vars(qtype))

#dns_data_fetched.sum_attacks_quarterly %>%
#  filter(qtype != "ANY") %>%
#  ggplot(aes(x = year_period, y = quantity)) +
#    geom_line() +
#   facet_wrap(facets = vars(qtype))

# ---------------------------------------- quantity with percentage



dns_data_fetched.sum_attacks_quarterly.sum_period_quantity = dns_data_fetched.sum_attacks_quarterly %>%
  group_by(year_period) %>%
  summarise(sum_period_quantity = sum(quantity), qtype=qtype, quantity=quantity)
```

```
## `summarise()` has grouped output by 'year_period'. You can override using the
## `.groups` argument.
```

```
dns_data_fetched.sum_attacks_quarterly.sum_period_quantity['quantity_percentage'] = (dns_data_fetched.su

#dns_data_fetched.sum_attacks_quarterly.sum_period_quantity %>%
#  filter(quantity_percentage > 0.001) %>%
#  filter(quantity_percentage > 0.1) %>%
  #ggplot(aes(x = year_period, y = quantity_percentage)) +
   # geom_line() +
    #facet_wrap(facets = vars(qtype))


#dns_data_fetched.sum_attacks_quarterly.sum_period_quantity %>%
#  filter(qtype != "ANY") %>%
#  ggplot(aes(x = year_period, y = quantity_percentage)) +
#    geom_line() +
#    facet_wrap(facets = vars(qtype))

#dns_data_fetched.sum_attacks_quarterly.sum_period_quantity %>%
  #mutate(year_period=as.factor(year_period)) %>%
#  filter(quantity_percentage > 0.1) %>%
#  ggplot(aes(x = year_period, y = quantity_percentage, color = qtype)) +
#  geom_line()

# ---------------------------------------- filter any

dns_data_fetched.sum_attacks_quarterly.sum_period_quantity.filter_any = dns_data_fetched.sum_attacks_qua
  group_by(year_period) %>%
  filter(qtype != "ANY") %>%
  summarise(sum_period_quantity = sum(quantity), qtype=qtype, quantity=quantity)
```

```
## `summarise()` has grouped output by 'year_period'. You can override using the
## `.groups` argument.
```

```
dns_data_fetched.sum_attacks_quarterly.sum_period_quantity.filter_any['quantity_percentage'] = (dns_data

#dns_data_fetched.sum_attacks_quarterly.sum_period_quantity.filter_any %>%
#  ggplot(aes(x = year_period, y = quantity_percentage)) +
#    geom_line() +
#    facet_wrap(facets = vars(qtype))
```

- A quantidade de requests em % por trimestre por qtype

```
dns_data_fetched.sum_attacks_quarterly.sum_period_quantity %>%
  ggplot(aes(x = year_period, y = quantity_percentage)) +
    geom_line() +
    facet_wrap(facets = vars(qtype))
```

```
## geom_path: Each group consists of only one observation. Do you need to adjust
## the group aesthetic?
## geom_path: Each group consists of only one observation. Do you need to adjust
## the group aesthetic?
```

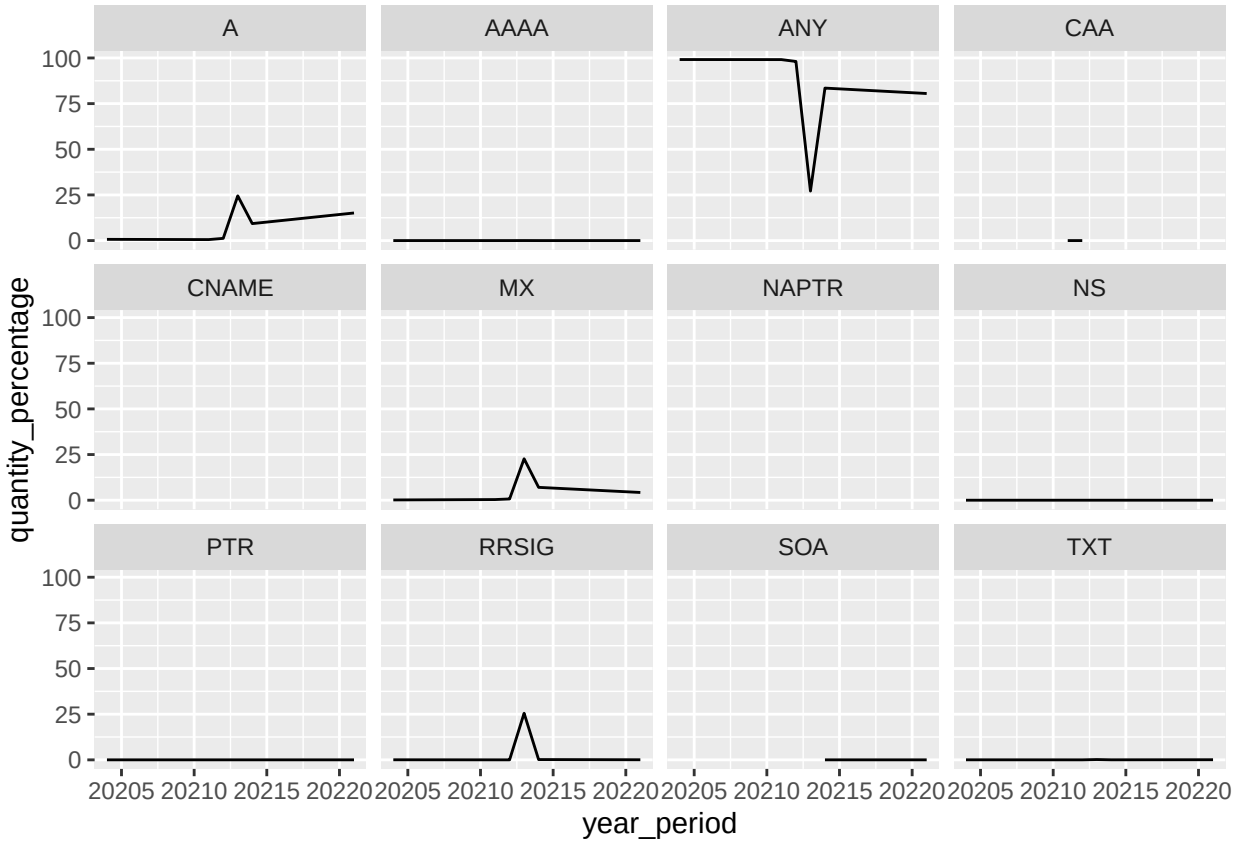

- A quantidade de requests em % por trimestre por qtype
  - lembrando que em 20213 teve um problema em armazenar os dados, por isso talvez essa discrepância

```
dns_data_fetched.sum_attacks_quarterly.sum_period_quantity %>%
  #mutate(year_period=as.factor(year_period)) %>%
  filter(quantity_percentage > 0.1) %>%
  ggplot(aes(x = year_period, y = quantity_percentage, color = qtype)) +
  geom_line()
```

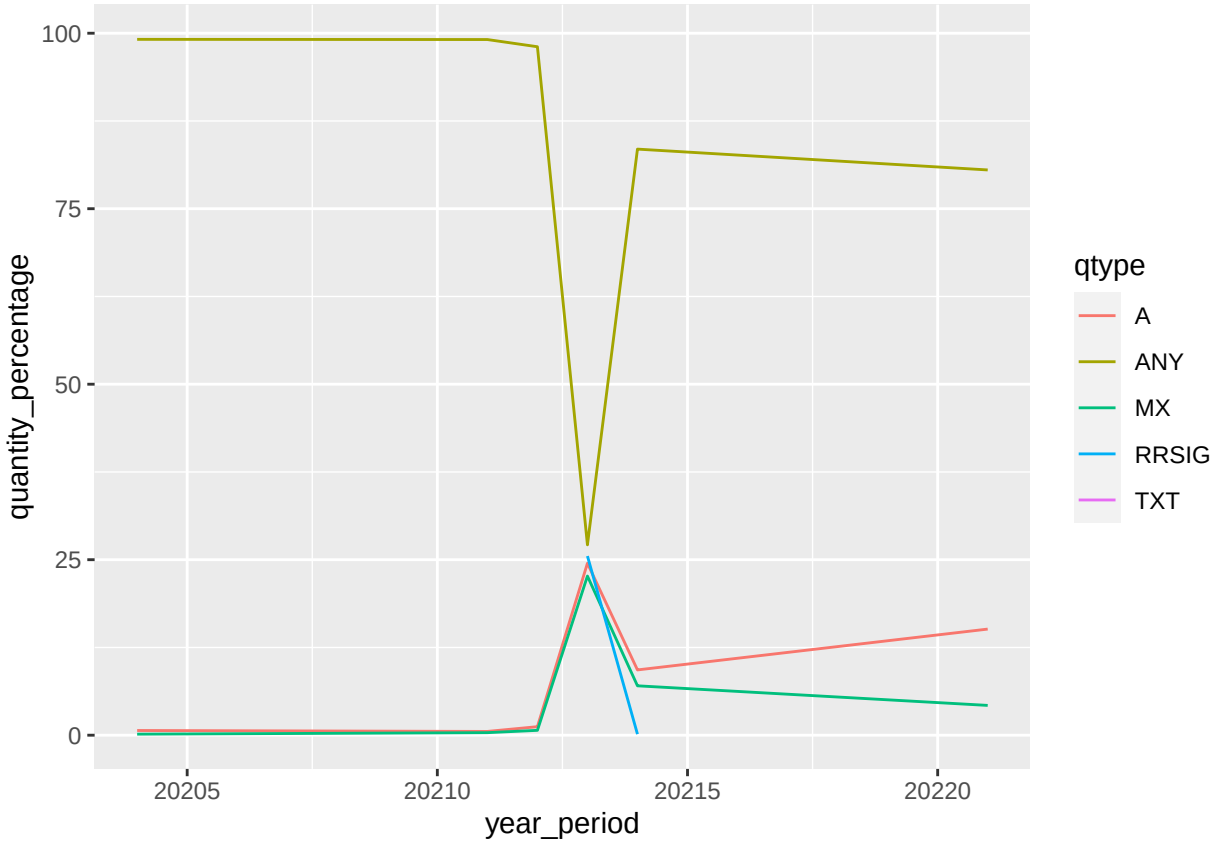

- Com esse gráfico é possível observar a grande quantidade de ataques do tipo ANY sendo extremamente superior aos demais, até mesmo no trimestre em que houve problema de armazenamento e alguns registros foram perdidos

- Quantos qnames e qtypes novos aparecem em cada trimestre

```
# ------------ Quantos qtypes novos aprecem em cada trimestre ------------
# > Diferenças percentuais são mais relevantes que absolutas

quarter_qtype_aux = dns_data.year_period.ungrouped[[1]] %>%
  group_by(qtype) %>%
  summarise(quantity = sum(quantity))

#quarter_qtype_2 = dns_data.year_period.ungrouped[[2]] %>%
#  group_by(qtype) %>%
#  summarise(quantity = sum(quantity))

#quarter_qtype_2
#merged = merge(x = quarter_qtype_aux, y = quarter_qtype_2, by = "qtype", all = TRUE)
#merged.new_quantity = merged$quantity.x - merged$quantity.y
#merged

quarter_new_qtype = data.frame()
for (i in c(2:dns_data.year_period.ungrouped.len)) {
  quarter_qtype = dns_data.year_period.ungrouped[[i]] %>%
    group_by(qtype) %>%
```

```
    summarise(quantity = sum(quantity))

  merged = merge(x = quarter_qtype_aux, y = quarter_qtype, by = "qtype", all = TRUE)
  merged.new_quantity = merged$quantity.x - merged$quantity.y

  perio_to_period = paste(head(dns_data.year_period.ungrouped[[i - 1]]['year'], 1), '.',  head(dns_data
  quarter_new_qtype <- rbind(quarter_new_qtype, data.frame(quarter_to_quarter=perio_to_period, merged$q

  quarter_qtype_aux = quarter_qtype
}

#quarter_new_qtype
#head(na.omit(quarter_new_qtype[order(-quarter_new_qtype$quantity_percentage),]))

# ------------ Quantos qname novos aprecem em cada trimestre ------------

quarter_qname_aux = dns_data.year_period.ungrouped[[1]] %>%
  group_by(qname) %>%
  summarise(quantity = sum(quantity))

quarter_new_qname = data.frame()
for (i in c(2:dns_data.year_period.ungrouped.len)) {
  quarter_qname = dns_data.year_period.ungrouped[[i]] %>%
    group_by(qname) %>%
    summarise(quantity = sum(quantity))

  merged = merge(x = quarter_qname_aux, y = quarter_qname, by = "qname", all = TRUE)
  merged.new_quantity = merged$quantity.x - merged$quantity.y

  period_to_period = paste(head(dns_data.year_period.ungrouped[[i - 1]]['year'], 1), '.',  head(dns_data
  quarter_new_qname <- rbind(quarter_new_qname, data.frame(quarter_to_quarter=period_to_period, merged$

  quarter_qname_aux = quarter_qname
}
#quarter_new_qname
#head(na.omit(quarter_new_qname[-order(quarter_new_qname$quantity_percentage_diff),]))
```

- Top 10 novos qtypes por trimestre

```
quarter_new_qtype %>%
  arrange(desc(sum_quantity)) %>%
  select('quarter_to_quarter', 'merged.qtype', 'sum_quantity') %>%
  head(N)
```

```
##      quarter_to_quarter merged.qtype sum_quantity
## 1  2020 . 4 -> 2021 . 1          ANY     17841217
## 2  2021 . 3 -> 2021 . 4          ANY      5133467
## 3  2021 . 2 -> 2021 . 3        RRSIG       325120
## 4  2021 . 3 -> 2021 . 4            A       297381
## 5  2021 . 2 -> 2021 . 3           MX       180707
## 6  2021 . 3 -> 2021 . 4           MX       171803
## 7  2021 . 2 -> 2021 . 3            A       121656
## 8  2020 . 4 -> 2021 . 1           MX       111066
```

```
## 9  2020 . 4 -> 2021 . 1            A        67349
## 10 2021 . 4 -> 2022 . 1          TXT          962
```

- Nessa tabela deveriamos desconsiderar todos os registros relacionados ao período 2021.3, então o registro mais relevante é o top 1 que indica que tiveram 17841217 novas requisições do tipo ANY do ultimo trimestre de 2020 para o primeiro trimestre de 2021
- Top 10 novos qnames por trimestre

```
quarter_new_qname %>%
  arrange(desc(sum_quantity)) %>%
  select('quarter_to_quarter', 'merged.qname', 'sum_quantity') %>%
  head(N)
```

```
##      quarter_to_quarter    merged.qname sum_quantity
## 1  2020 . 4 -> 2021 . 1 peacecorps.gov.     13689398
## 2  2021 . 3 -> 2021 . 4 peacecorps.gov.      4844048
## 3  2020 . 4 -> 2021 . 1        isc.org.      2408612
## 4  2020 . 4 -> 2021 . 1             sl.      2252507
## 5  2021 . 1 -> 2021 . 2        irs.gov.       534808
## 6  2021 . 3 -> 2021 . 4             sl.       441886
## 7  2020 . 4 -> 2021 . 1        fe18.ru.       371672
## 8  2021 . 2 -> 2021 . 3   pizzaseo.com.       323981
## 9  2020 . 4 -> 2021 . 1               .       120727
## 10 2021 . 2 -> 2021 . 3               .        76494
```

-
- Gráfico de barras da porcentagem de qtypes por trimestre

```
dns_data_fetched.sum_attacks_quarterly.sum_period = dns_data_fetched.sum_attacks_quarterly %>%
  group_by(year_period) %>%
  summarise(period_quantity = sum(quantity), qtype=qtype, quantity=quantity)
```

```
## `summarise()` has grouped output by 'year_period'. You can override using the
## `.groups` argument.
```

```
dns_data_fetched.sum_attacks_quarterly.sum_period['quantity_percentage'] = (dns_data_fetched.sum_attacks
```

- A porcentagem calculada pela quantidade de requisições em cada período por cada qtype

```
dns_data_fetched.sum_attacks_quarterly.sum_period %>%
  mutate(year_period=as.factor(year_period)) %>%
  filter(quantity_percentage > 0.1) %>%
  ggplot( aes(x=reorder(qtype, -quantity_percentage), y=quantity_percentage, fill=qtype)) +
    geom_bar(stat="identity", position="dodge") +
    scale_fill_viridis(discrete=TRUE, name="") +
    geom_text(aes(label = paste(round(quantity_percentage, 2), "%")), vjust = +0.25, ) +
    facet_grid(~year_period) +
    ylab("Percentage of attacks") +
    ggtitle("All QTYPES - ungrouped bar")
```

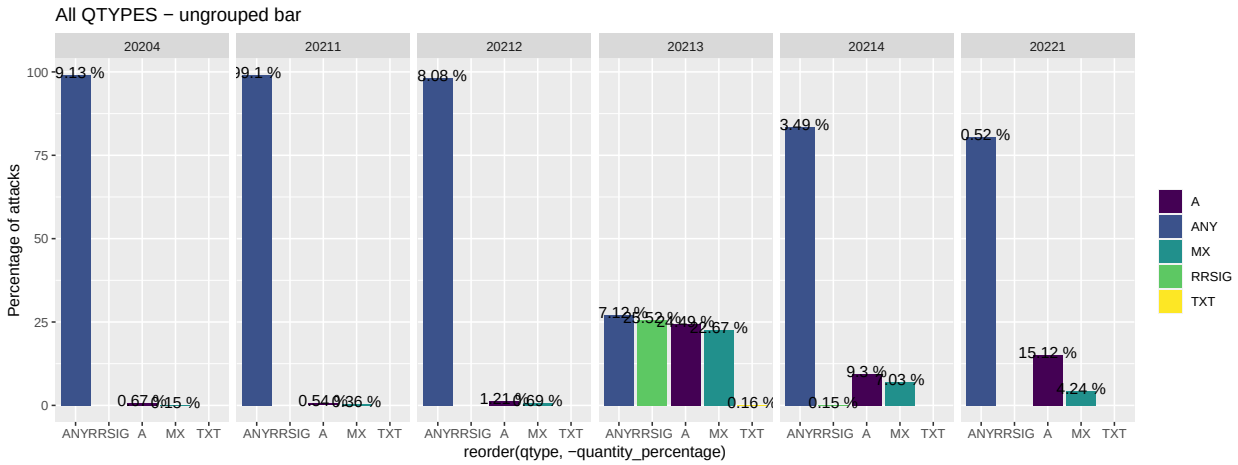

- Novamente a porcentagem calculada pela quantidade de requisições em cada período por cada qtype, cada barra é um trimestre

```
dns_data_fetched.sum_attacks_quarterly.sum_period %>%
  mutate(year_period=as.factor(year_period)) %>%
  filter(quantity_percentage > 0.1) %>%
  ggplot( aes(x=year_period, y=quantity_percentage, fill=qtype)) +
    geom_bar(stat="identity", width = 0.5) +
    geom_text(aes(label = paste(round(quantity_percentage, 2), "%")), position = position_stack(vjust =
    scale_fill_viridis(discrete=TRUE, name="") +
    ylab("Percentage of attacks") +
    ggtitle("All QTYPES - stacked bars")
```

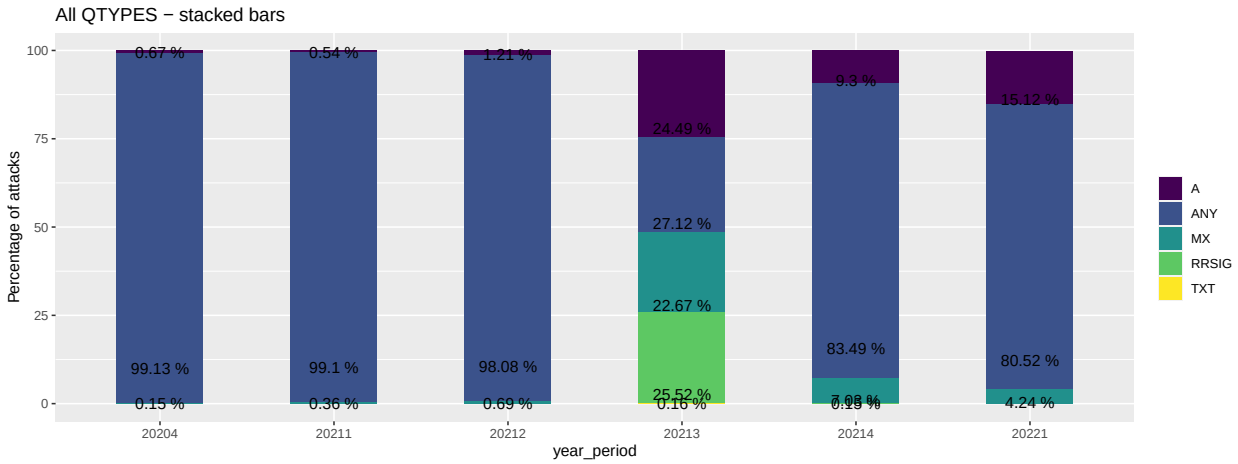

- Porcentagem da quantidade de requisições por trimestre por qtype em que tenha no mínimo 1% de requisições totais realizadas

```
## Filter data using qtype quantity percentage bigger than 1

dns_data_fetched.sum_attacks_quarterly.sum_period %>%
  filter(quantity_percentage > 1) %>%
  mutate(year_period=as.factor(year_period)) %>%
  ggplot( aes(x=reorder(qtype, -quantity_percentage), y=quantity_percentage, fill=qtype)) +
    geom_bar(stat="identity", position="dodge") +
```

```
    geom_text(aes(label = paste(round(quantity_percentage, 2), "%")), vjust = -0.25) +
    facet_grid(~year_period) +
    scale_fill_viridis(discrete=TRUE, name="") +
    ylab("Percentage of attacks") +
    ggtitle("QTYPES > 1% by period - ungrouped bars")
```

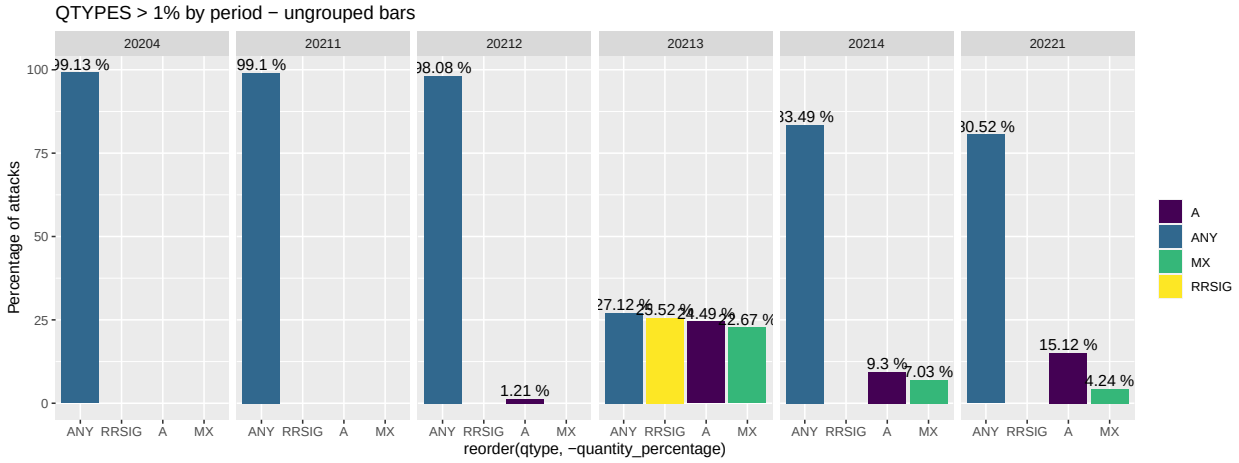


```
dns_data_fetched.sum_attacks_quarterly.sum_period %>%
  filter(quantity_percentage > 1) %>%
  mutate(year_period=as.factor(year_period)) %>%
  ggplot( aes(x=year_period, y=quantity_percentage, fill=qtype)) +
    geom_bar(stat="identity", width = 0.5) +
    geom_text(aes(label = paste(round(quantity_percentage, 2), "%")), position = position_stack(vjust =
    scale_fill_viridis(discrete=TRUE, name="") +
    ylab("Percentage of attacks") +
    ggtitle("QTYPES > 1% by period - stacked bars")
```

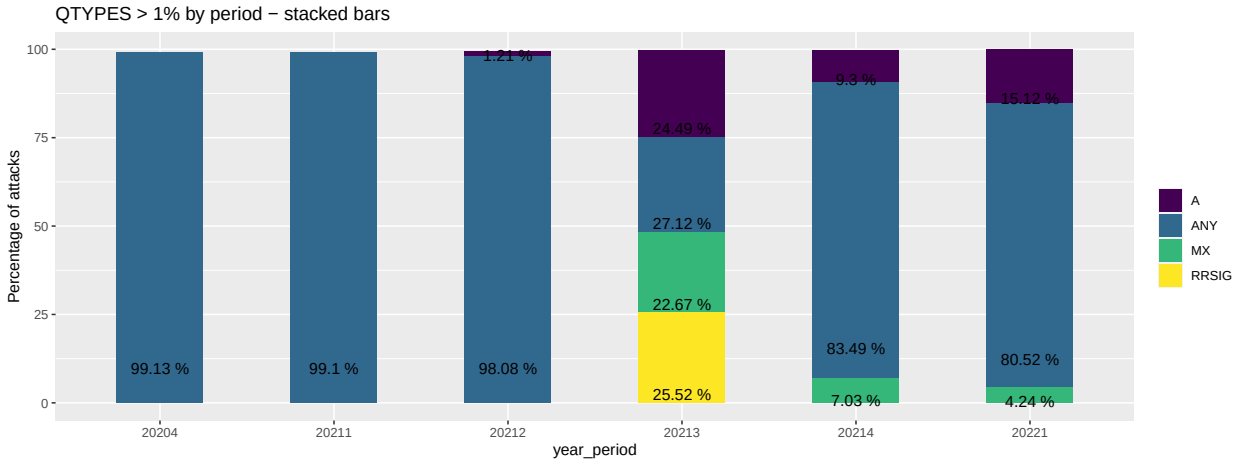

- Com esse gráfico é possível observar a grande quantidade de ataques do tipo ANY sendo extremamente superior aos demais, levando a crer que a depreciação da query do tipo ANY vazia nos servidores DNS não afetou o modo em que os ataques são realizados, até mesmo porque inúmeros servidores DNS não se atualizaram e não depreciaram esse modo de realizar as queries

- Quantidade de requisições por trimestre

```
dns_data_fetched.sum_attacks_quarterly.sum_period %>%
  mutate(year_period=as.factor(year_period)) %>%
  ggplot( aes(x=year_period, y=period_quantity)) +
    geom_bar(stat="identity", width = 0.5) +
    scale_fill_viridis(discrete=TRUE, name="") +
    ylab("Quantity of attacks") +
    ggtitle("Attacks by period")
```

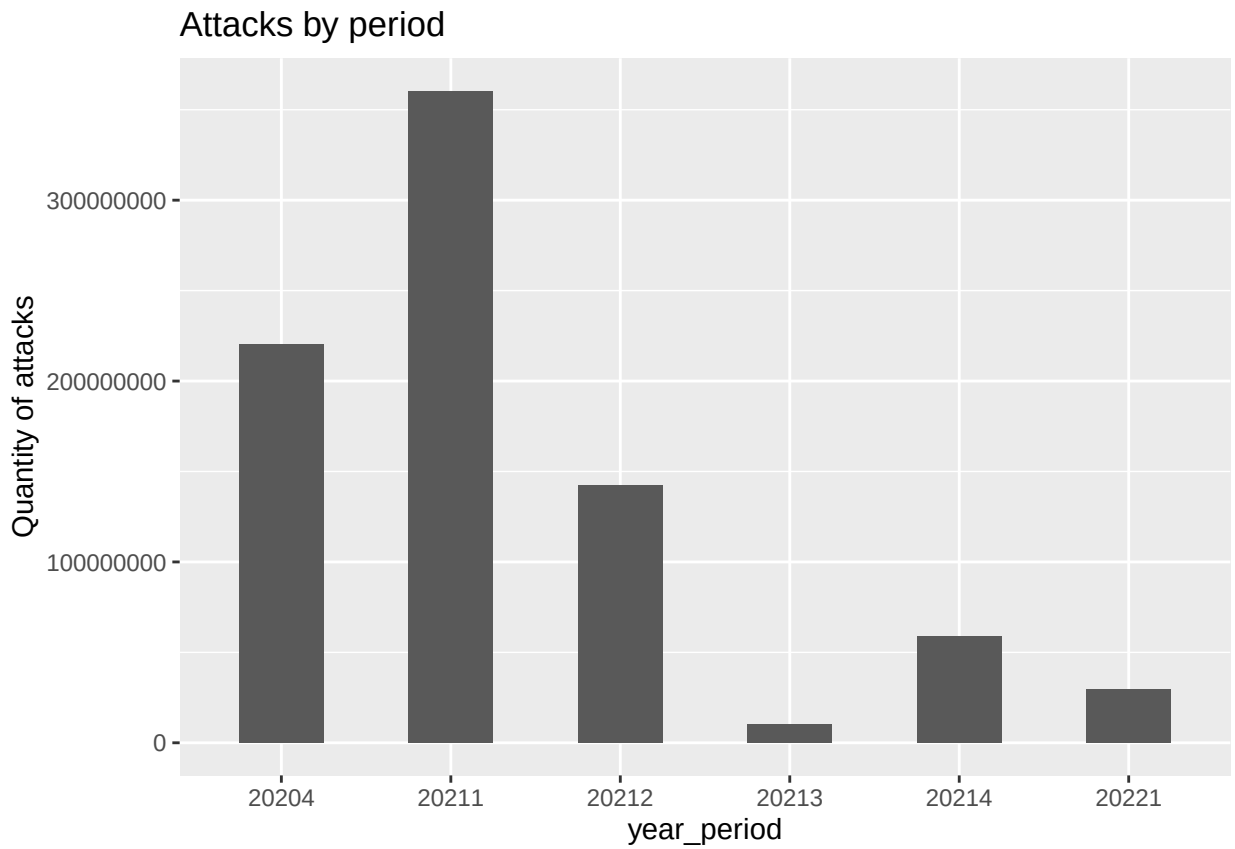

- Em quantidade de ataques, obtivemos um pico no primeiro trimestre de 2021, e logo vamos poder comparar com o primeiro trimestre de 2022 para verificar se geralmente o primeiro trimestre é aquele em que ocorrem a maior quantidade de ataques no ano

- Os 10 ataques em que tiveram uma maior sobreposição de tempo entre o início e o fim do ataque com um mesmo query_id

```
dns_data_overlap_fetched %>%
  arrange(desc(amount_overlap)) %>%
  head(5)
```

```
##       id tempo_inicio_datetime tempo_final_datetime query_id qtype   qname
## 1 248406   2021-02-03 11:13:01  2021-02-03 18:56:55    17767   ANY wzb.eu.
## 2 241613   2021-01-31 16:50:23  2021-01-31 22:34:50    17767   ANY     sl.
## 3 243903   2021-02-01 19:25:25  2021-02-01 22:14:16    17767   ANY     sl.
```

```
## 4 261733   2021-02-09 00:11:08  2021-02-09 05:53:30    17767   ANY     sl.
## 5 268519   2021-02-11 15:06:02  2021-02-11 17:28:15    17767   ANY     sl.
##   requests_per_attack             ip amount_overlap
## 1               95308 78.128.114.125            658
## 2               19754  73.95.243.160            527
## 3                 590   174.99.5.206            270
## 4                1444  76.107.212.17            257
## 5                1453 172.101.205.51            235
```

- Isso possívelmente indica que alguns atacantes utilizaram-se da mesma ferramenta para realizar o ataque para diferentes domínios e nem sequer modificaram o query_id, ou utilizaram algum modo de incremento para ofuscar o ataque

Texto

Dados

- Esse documento teve como dados apenas os ataques que utilizam DNS. Esses ataques foram recolhidos pelo MP-H entre o período de 29/10/2020 até 24/02/2022.
- Os datasets com os ataques DNS foram processados por um script em python que faz o parse do payload para recolher informações do DNS como:
  - O query_id que é o TX ID da transação definido pelo atacante;
  - O qname que é o domínio em que o atacante realizou spoffing;
  - O qtype que é o tipo da query utilizada para realizar amplificação.

Questões

- A ideia para esse documento é realizar uma análise longitudinal da evolução dos payloads somente para evoluções relacionadas a ataques DNS.
- Uma das analises destacadas é o uso do DNS com o QTYPE ANY. Pois, historicamente ataques DRDoS com DNS utilizam majoritariamente requisições para o QTYPE ANY, que retorna todos os tipos de registros para um dado nome. Assim, será que a incidência de requisições com ANY evoluiu ao longo do tempo?
- Para contexto, requisições com o QTYPE ANY tem um grande potencial de amplificação e o seu uso legítimo é apenas para debug do servidor e para verificar o estado de um servidor DNS, por esse motivo, foi introduzida uma recomendação para que servidores DNS reduzam ou limitem o tamanho na resposta das consultas com QTYPE ANY (RFC8482) para evitar o uso dessas requisições em ataques de negação de serviço por reflexão ou tornar essa forma de amplificação menos útil aos atacantes.

Analises

- Obs.: Tenha em mente que os dados referentes ao terceiro trimestre de 2021 podem não refletir a realidade, devido a alguns problemas de armazenamento durante esse período.

Quantidade de requisições por QTYPE e trimestres

- Para realizar a análise, foi realizado uma query agrupando os registros do DNS por (year_period, year, period, qname, qtype) e somado a quantidade total de requisições (request_per_attack) e renomeado para (quantity)

- Dessa forma, foi analisado a porcentagem de cada QTYPE dentre as consultas por trimestre de DNS já processados, em que a porcentagem foi definida pela soma total das requisições por ataques de um mesmo tipo por trimestre. Então por exemplo se em um mesmo trimestre a soma total das requisições dos ataques com o QTYPE MX for 20 e o total das requisições dos ataques do tipo ANY for 80, a porcentagem de ANY será 80% e de MX será 20% naquele trimestre.

```
dns_data_fetched.sum_attacks_quarterly.sum_period %>%
  mutate(year_period=as.factor(year_period)) %>%
  filter(quantity_percentage > 0.1) %>%
  ggplot( aes(x=year_period, y=quantity_percentage, fill=qtype)) +
    geom_bar(stat="identity", width = 0.55) +
    geom_text(aes(label = paste(round(quantity_percentage, 2), "%")), position = position_stack(vjust =
    scale_fill_viridis(discrete=TRUE, direction = -1) +
    ylab("Percentage of attacks") +
    ggtitle("All QTYPES - stacked bars")
```

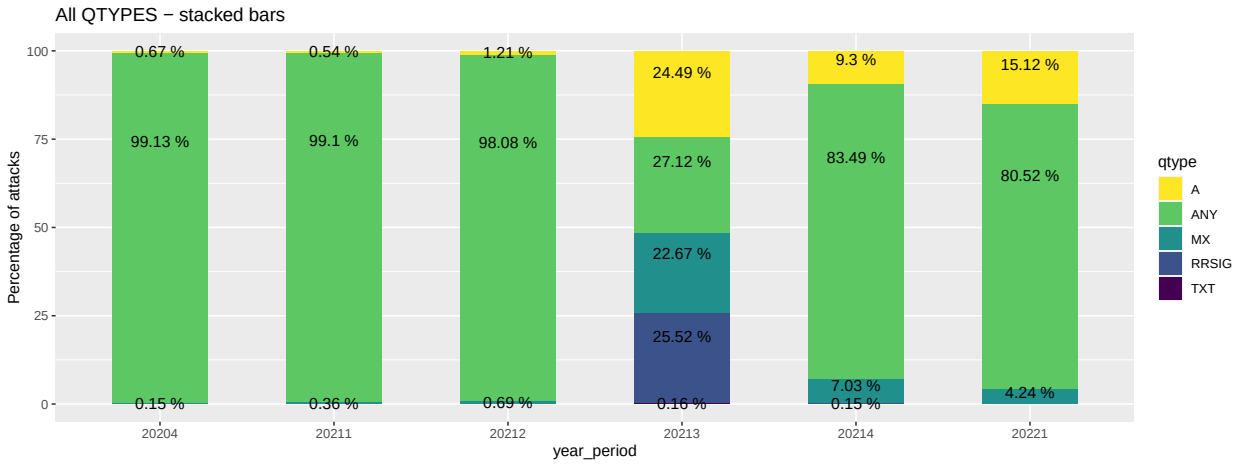

- Esse gráfico apresenta que ANY é a maioria em todos os trimestre em que os dados foram coletados com uma predominância grande (98%+) nos três primeiros trimestres (2020/Q4, 2021/Q1, 2021/Q2) e teve uma queda nos dois últimos trimestres com 83.49% em 2021/Q4 e 80.52% 2022/Q1 liberando a entrada dos QTYPES A e MX que juntos somam 16.32% em 2021/Q4 e 19.36% em 2021/Q5.
- Valores abaixo de 1.5% no gráfico foram desconsiderados

Quantidade de ataques por query_id e sobreposição

- Para iniciar essa análise de dados foi verificado que inúmeros ataques utilizavam o mesmo query_id, como apresentado no top 5 abaixo que o query_id "17767" foi utilizado em 87.924 ataques diferentes somando 9.063.853 requisições utilizando o mesmo query_id entre cerca de 30 domínios diferentes e isso levantou algumas dúvidas, pois o query_id deveria ser aletório conforme estabelecido na RFC5452 em que resolvedores DNS precisam utilizar um número de query ID aleatório entre (0-65535), totalizando 2^16 possíveis valores para o query_id. Dessa forma, uma dúvida que surge é porque tantos ataques utilizam o mesmo query_id?
  - Uma curiosidade é que o query_id mais utilizado "17767" em hexadecimal é 0x4567 que são 4 números consecutivos

```r
data %>%
  group_by(query_id) %>%
  summarise(requests_per_attack = sum(requests_per_attack), n = n(), qnames_diff = n_distinct(qname)) %>
  arrange(desc(n)) %>%
  head(5)
```

```
## # A tibble: 5 x 4
##   query_id requests_per_attack     n qnames_diff
##      <int>               <int> <int>       <int>
## 1    17767             9063853 87924          30
## 2    26566             9019358 40940           1
## 3        1              401246  7803        1311
## 4    13551                5961  2347           3
## 5    16049               17634  1062           3
```

- Uma teoria que vem a mente é que como muitos desses ataques utilizaram o mesmo query_id, talvez eles utilizem a mesma ferramenta para realizar esses ataques e nem se deram ao trabalho de alterar o query_id ou utilizar um número randômico para realizar os ataques...
- Um destaque relacionado ao query_id é que ele deve ser aleatório, mas pode repetir pois existem apenas 65.536 possibilidades de números distintos (de 0 a 65535) que é o tamanho de um cabeçalho de 16 bits. Então, a partir de 65.536 requisições com o mesmo qname o query_id probabiliticamente iniciaria a se repetir, o que torna anômalo os casos listados a baixo em que o query_id repetiu 58.001 vezes enquanto probabilisticamente deveria repetir aproximadamente 40x (requests_per_attack / 65.536)

```r
possible_query_id = 65536

data %>%
  group_by(query_id, qname) %>%
  summarise(requests_per_attack = sum(requests_per_attack), query_id_repeated = n()) %>%
  mutate(probabilist_repetion = as.integer(requests_per_attack/possible_query_id)) %>%
  arrange(desc(query_id_repeated)) %>%
  head(5)
```

```
## `summarise()` has grouped output by 'query_id'. You can override using the
## `.groups` argument.
```

```
## # A tibble: 5 x 5
## # Groups:   query_id [4]
##   query_id qname           requests_per_attack query_id_repeat~ probabilist_rep~
##      <int> <chr>                         <int>            <int>            <int>
## 1    17767 isc.org.                    2652120            58001               40
## 2    26566 peacecorps.gov.             9019358            40940              137
## 3    17767 sl.                         5947165            29801               90
## 4        1 pizzaseo.com.                331233             6442                5
## 5    13551 VERSION.BIND.                 5938             2335                0
```

- Essa diferença gigante entre a quantidade de vezes que o query_id repetiu e a probabilidade em que poderia repetir auxilia no embasamento da utilização de uma mesma ferramenta pelos atacantes.
- Uma outra teoria é que se ataques com o mesmo query_id acontecem em paralelo a outro ataque com qname diferente, possívelmente existe um atacante que comanda inúmeros diferentes ataques ao mesmo tempo ou colabora para a teoria de que vários atacantes utilizam a mesma ferramenta para realizar os ataques e esses ataques são sincronizados para acontecerem em um mesmo período.

- Para verificar se ataques com um mesmo qtype e query_id acontecem em paralelo a diferentes qnames é necessário verificar se esses ataques são concomitantes, ou seja, observar se um ataque acontece enquanto outro ataque com o mesmo query_id acontece. O cálculo da quantidade de ataques concomitantes foi verificado se o tempo inicio de um ataque esta entre o inicio e fim de outro ataque ou o tempo final esta entre o inicio e fim de outro ataque, é somado 1 ao contador (amount_overlap).

```
dns_data_overlap_fetched %>%
  arrange(desc(amount_overlap)) %>%
  select('query_id', 'qtype', 'qname', 'requests_per_attack', 'ip', 'amount_overlap') %>%
  head(5)
```

```
##   query_id qtype   qname requests_per_attack            ip amount_overlap
## 1    17767   ANY wzb.eu.               95308 78.128.114.125            658
## 2    17767   ANY     sl.               19754  73.95.243.160            527
## 3    17767   ANY     sl.                 590   174.99.5.206            270
## 4    17767   ANY     sl.                1444  76.107.212.17            257
## 5    17767   ANY     sl.                1453 172.101.205.51            235
```

- Com a tabela acima é possível observar que existe muita sobreposição entre os ataques que utilizam o mesmo QTYPE e o mesmo query_id com o ataque para o domínio "wzb.eu." que teve 658 ataques com o mesmo query_id "17767" e qtype "ANY" ocorrendo durante o período em que esse ataque ocorria.

Conclusões

- Enfim, os ataques com o QTYPE "ANY" ainda são os mais utilizados em todos os períodos, indicando que a redução no tamanho da resposta desse tipo de query não modificou ou não limitou o fator amplificação o suficiente para que os atacantes parem de abusar. Assim os atacantes continuam abusando dessa query na realização de seus ataques, muito provavelmente devido ao fato de servidores DNS não realizarem atualizações para se adequarem as recomendações apresentadas na RFC8482 para limitar o tamanho da resposta e assim tornar esse modo de amplificação menos útil aos atacantes.

- Além disso, o grande número de ataques utilizando o mesmo query_id e também a quantidade de sobreposição entre os ataques indicam que muitos deles utilizaram a mesma ferramenta para realizar os ataques. Ainda mais pois os atacantes nem sequer se deram ao trabalho de alterar o query_id ou utilizar um número randômico/incremental para o query_id ser diferente.