DN2. DNS: longevidade de nomes

Rafilx

2022-05-02

```
##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
##     filter, lag

## The following objects are masked from 'package:base':
##
##     intersect, setdiff, setequal, union

## Loading required package: viridisLite

##
## Attaching package: 'lubridate'

## The following objects are masked from 'package:base':
##
##     date, intersect, setdiff, union
```

R Markdown

A longevidade de um nome (QNAME+QTYPE) no dataset pode ser definida como o intervalo entre a primeira e a última aparição desse nome. Calcular a longevidade dos nomes no dataset, e analisar como essa variável está distribuída.

Resultados esperados:

- análise gráfica da distribuição (histograma, ECDF) e numérica (min, max, média, mediana) da longevidade dos nomes
  - por enquanto não vejo sentido em dividir a análise por período, então pode considerar o dataset como um todo
  - minha intuição é que a distribuição seja assimétrica com (longa) cauda à direita
- Busca os dados no banco com o parse do DNS ja realizado, então temos:
  - qname que é o domínio
  - QTYPE tipo da query
  - query_id ID da transação definido pelo atacante
  - year_period ano e trimestre em que ocorreu o ataque exemplo "20212" o ataque ocorreu no segundo trimestre do 2021

```
db <- dbConnect(RSQLite::SQLite(), dbname="../db/database-2022-05-11/dnstor_statistics_dns.sqlite")

data_unfetch <-dbSendQuery(db, "
  SELECT *, CAST(CAST(year AS text) || CAST(period AS text) as integer) as year_period
    FROM DNS_ANALYSIS
        JOIN DNS_ANALYSIS_QUESTION
          ON DNS_ANALYSIS.id = DNS_ANALYSIS_QUESTION.dns_analysis_id
     WHERE QTYPE != 0
")
data <- fetch(data_unfetch)

dbDisconnect(db)
```

```
## Warning in connection_release(conn@ptr): There are 1 result in use. The
## connection will be released when they are closed
```

```
data['tempo_final_cast'] = as.POSIXct(data[['tempo_final']], format = "%Y-%m-%d %H:%M:%S")
data['tempo_inicio_cast'] = as.POSIXct(data[['tempo_inicio']], format = "%Y-%m-%d %H:%M:%S")

secs_to_hours = (60 * 60)
secs_to_days = (secs_to_hours * 24)

data_grouped = data %>%
  group_by(qname, qtype) %>%
  summarise(tempo_inicio=min(tempo_inicio_cast), tempo_final=max(tempo_final_cast),
            sum_requests_per_attack=sum(requests_per_attack), number_of_attacks=n()) %>%
  mutate(tempo_diff_secs = as.numeric(tempo_final - tempo_inicio, units="secs"),
         tempo_diff = tempo_final - tempo_inicio,
         avg_requests_per_attack=trunc(sum_requests_per_attack/number_of_attacks)) %>%
  arrange(desc(tempo_diff_secs))
```

```
## `summarise()` has grouped output by 'qname'. You can override using the
## `.groups` argument.
```

```
data_grouped %>%
  head(10)
```

```
## # A tibble: 10 x 9
## # Groups:   qname [10]
##    qname          qtype tempo_inicio        tempo_final         sum_requests_pe~
##    <chr>          <chr> <dttm>              <dttm>                         <int>
##  1 VERSION.BIND.  TXT   2020-10-30 02:39:27 2022-05-11 13:05:22            6160
##  2 peacecorps.go~ ANY   2020-10-31 14:28:23 2022-05-11 05:22:49        72734156
##  3 200-19-107-23~ A     2020-10-30 11:15:36 2022-05-09 21:23:22             148
##  4 version.bind.  TXT   2020-11-01 04:46:10 2022-05-11 12:13:52             833
##  5 a.gtld-server~ A     2020-10-30 02:55:07 2022-05-09 06:50:12              89
##  6 com.           ANY   2020-10-31 11:38:32 2022-05-09 16:38:23             511
##  7 238.107.19.20~ PTR   2020-11-01 23:58:38 2022-05-09 04:56:13             842
##  8 dns-test.rese~ TXT   2020-11-04 06:49:48 2022-05-11 09:58:47              87
##  9 mopa.ae.       MX    2020-11-04 14:39:23 2022-05-11 13:52:05            6096
## 10 szgmc.gov.ae.  MX    2020-11-03 14:47:10 2022-05-10 13:29:54             889
## # ... with 4 more variables: number_of_attacks <int>, tempo_diff_secs <dbl>,
## #   tempo_diff <drtn>, avg_requests_per_attack <dbl>
```

```
data_grouped %>%
  ggplot(aes(x= tempo_diff_secs)) +
  geom_histogram(bins = 10, fill='blue', color ='black') +
  ggtitle("Longevidade de um mesmo (QNAME + QTYPE)") +
  xlab("tempo_final - tempo_inicio") +
  theme_classic()
```

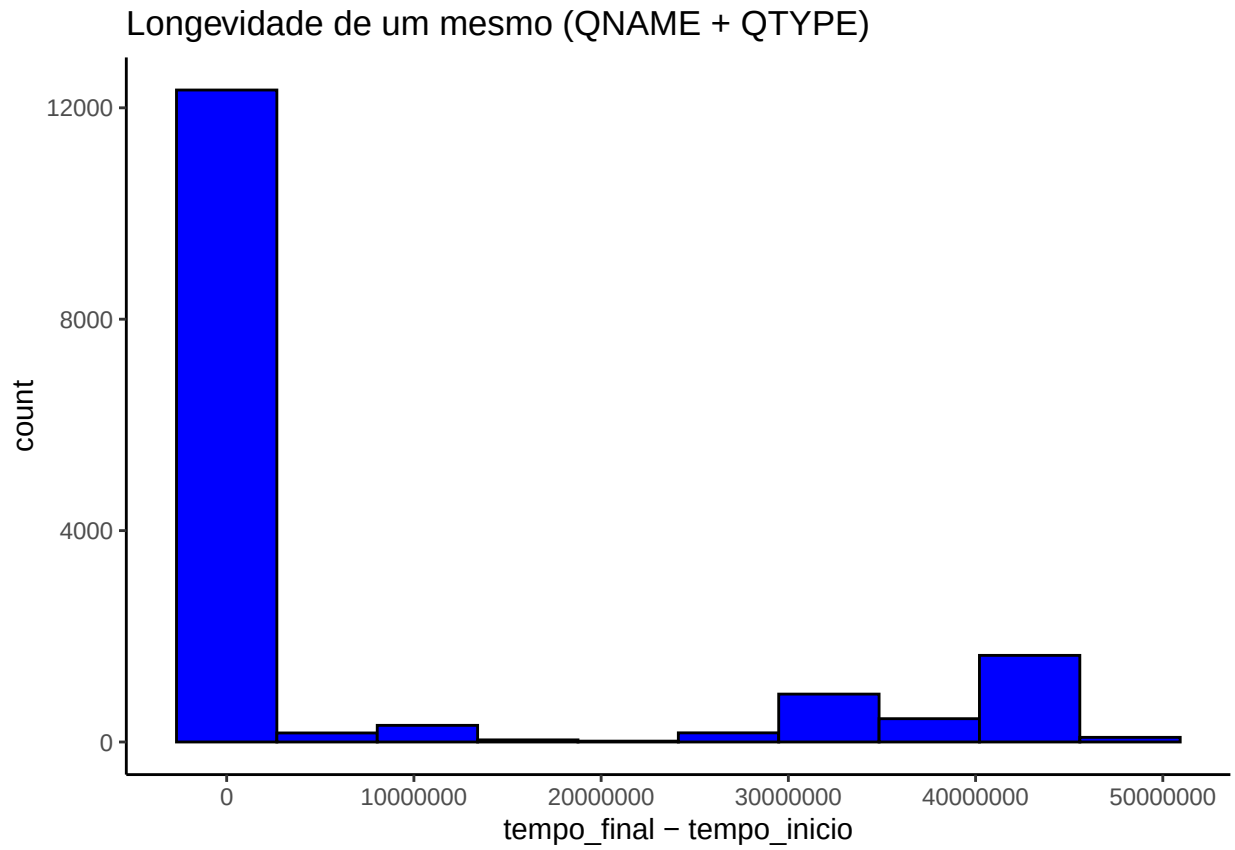


```
data_grouped %>%
  ggplot(aes(x= tempo_diff_secs)) +
  stat_ecdf(geom = "step", pad = FALSE) +
  ggtitle("Longevidade de um mesmo (QNAME + QTYPE)") +
  xlab("tempo_final - tempo_inicio") +
  theme_classic()
```

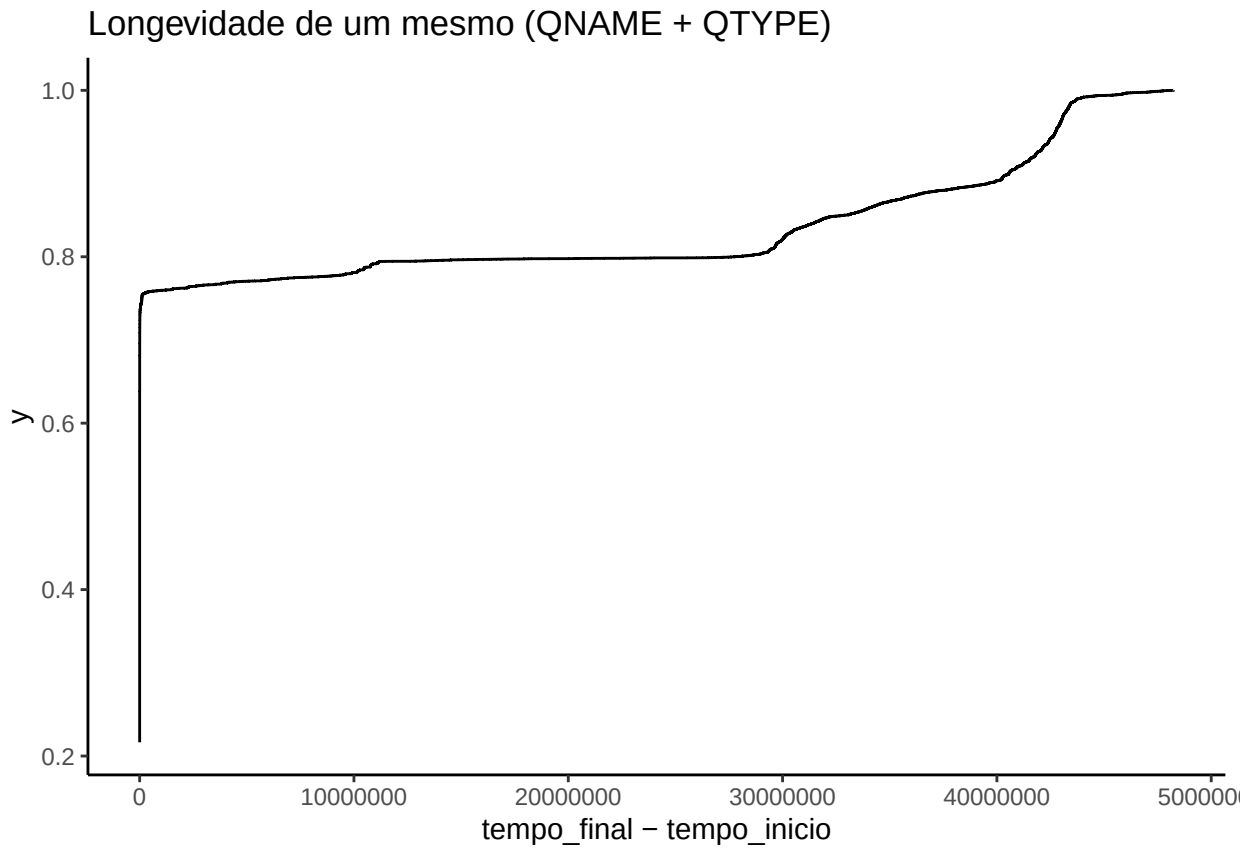


```
data_grouped.tempo_diff_secs.min = min(data_grouped$tempo_diff_secs)
data_grouped.tempo_diff_secs.max = max(data_grouped$tempo_diff_secs)
data_grouped.tempo_diff_secs.mean = mean(data_grouped$tempo_diff_secs)
data_grouped.tempo_diff_secs.median = median(data_grouped$tempo_diff_secs)

quantile(data_grouped$tempo_diff_secs)
```

```
##       0%      25%      50%      75%     100%
##        0        5       67   105178 48248755
```

```
summary(data_grouped)
```

```
##     qname              qtype            tempo_inicio
##  Length:16125       Length:16125       Min.   :2020-10-29 16:15:05
##  Class :character   Class :character   1st Qu.:2020-12-17 16:50:24
##  Mode  :character   Mode  :character   Median :2021-07-09 00:38:37
##                                        Mean   :2021-06-25 05:28:30
##                                        3rd Qu.:2021-11-15 13:56:59
##                                        Max.   :2022-05-11 13:22:23
##   tempo_final                  sum_requests_per_attack number_of_attacks
##  Min.   :2020-10-29 23:17:13   Min.   :       1        Min.   :     1
##  1st Qu.:2021-03-08 14:18:01   1st Qu.:       2        1st Qu.:     1
##  Median :2021-11-01 10:55:05   Median :       9        Median :     1
##  Mean   :2021-09-25 18:50:31   Mean   :    5580        Mean   :    36
```

```
##  3rd Qu.:2022-04-02 11:48:10   3rd Qu.:     101        3rd Qu.:     4
##  Max.   :2022-05-11 14:41:27   Max.   :72734156        Max.   :118333
##  tempo_diff_secs     tempo_diff       avg_requests_per_attack
##  Min.   :       0   Length:16125      Min.   :    1
##  1st Qu.:       5   Class :difftime   1st Qu.:    2
##  Median :      67   Mode  :numeric    Median :    8
##  Mean   : 7996921                     Mean   :   25
##  3rd Qu.:  105178                     3rd Qu.:   21
##  Max.   :48248755                     Max.   :18556
```

- Dados sobre o intervalo entre a primeira e a última aparição desse (QNAME+QTYPE)
  - Mínimo 0 segundos
  - Máximo 558.4347 meses
  - Média 133282.019 minutos
  - Mediana 67 segundos

```
trim_value = .1

data_grouped.tempo_diff_secs.min = min(data_grouped$tempo_diff_secs, trim=trim_value)
data_grouped.tempo_diff_secs.max = max(data_grouped$tempo_diff_secs, trim=trim_value)
data_grouped.tempo_diff_secs.mean = mean(data_grouped$tempo_diff_secs, trim=trim_value)
data_grouped.tempo_diff_secs.median = median(data_grouped$tempo_diff_secs, trim=trim_value)

quantile(data_grouped$tempo_diff_secs, trim=trim_value)
```

```
##       0%      25%      50%      75%     100%
##        0        5       67   105178 48248755
```

```
summary(data_grouped, trim=trim_value)
```

```
##     qname              qtype            tempo_inicio
##  Length:16125       Length:16125       Min.   :2020-10-29 16:15:05
##  Class :character   Class :character   1st Qu.:2020-12-17 16:50:24
##  Mode  :character   Mode  :character   Median :2021-07-09 00:38:37
##                                        Mean   :2021-06-25 05:28:30
##                                        3rd Qu.:2021-11-15 13:56:59
##                                        Max.   :2022-05-11 13:22:23
##   tempo_final                  sum_requests_per_attack number_of_attacks
##  Min.   :2020-10-29 23:17:13   Min.   :       1        Min.   :     1
##  1st Qu.:2021-03-08 14:18:01   1st Qu.:       2        1st Qu.:     1
##  Median :2021-11-01 10:55:05   Median :       9        Median :     1
##  Mean   :2021-09-25 18:50:31   Mean   :    5580        Mean   :    36
##  3rd Qu.:2022-04-02 11:48:10   3rd Qu.:     101        3rd Qu.:     4
##  Max.   :2022-05-11 14:41:27   Max.   :72734156        Max.   :118333
##  tempo_diff_secs     tempo_diff       avg_requests_per_attack
##  Min.   :       0   Length:16125      Min.   :    1
##  1st Qu.:       5   Class :difftime   1st Qu.:    2
##  Median :      67   Mode  :numeric    Median :    8
##  Mean   : 7996921                     Mean   :   25
##  3rd Qu.:  105178                     3rd Qu.:   21
##  Max.   :48248755                     Max.   :18556
```

- Dados sobre o intervalo entre a primeira e a última aparição do (QNAME+QTYPE) removendo 10% dos valores máximos e mínimos
  - Mínimo 0 segundos
  - Máximo 558.4347 meses
  - Média 77605.1631 minutos
  - Mediana 67 segundos
- Identificar qual é o percentil em que há essa mudança de tendência (próximo aos 72-73%) e qual a duração correspondente

```
quantile(data_grouped$tempo_diff_secs,
         c(.5332, .6235, .696282, .710307, .72, .7204,
           .721090026, .73, .7396902445, .75, .76,
           .77, .78, .99))
```

```
##     53.32%     62.35%     69.63%     71.03%        72%     72.04%     72.11%
##       70.0      745.6     3602.7     5457.6     7265.0     7434.6     7764.7
##        73%     73.97%        75%        76%        77%        78%        99%
##    12521.6    41400.8   105178.0  1229816.9  4526143.5  9874846.8 43799901.3
```

- Isso representa que Y% dos (QNAME+TYPE), tem os seus ataques com duração de até X segundos:
  - 53.3% até 100 segundos
  - 62.3% até 1000 segundos
  - 69.6% até 10000 segundos
  - 71% até 100000 segundos
  - 72% até 598289 segundos
  - 72.04% até 803076 segundos
  - 72.11% até 1000000 segundos
  - 73.97% até 10000000 segundos
- Significa que após os (69%) o tempo dos ataques cresceu de 27.7778 até 115.7407 (73.97%) onde estabiliza próximo dos 10000000 segundos
- Uma representação ECDF removendo os registros abaixo da quantidade de segundos em que apresenta estabilidade (10000000 segundos)

```
data_grouped %>%
  filter(tempo_diff_secs > 10000000) %>%
  ggplot(aes(x= tempo_diff_secs)) +
  stat_ecdf(geom = "step", pad = FALSE) +
  ggtitle("Longevidade de um mesmo (QNAME + QTYPE)") +
  xlab("tempo_final - tempo_inicio") +
  theme_classic()
```

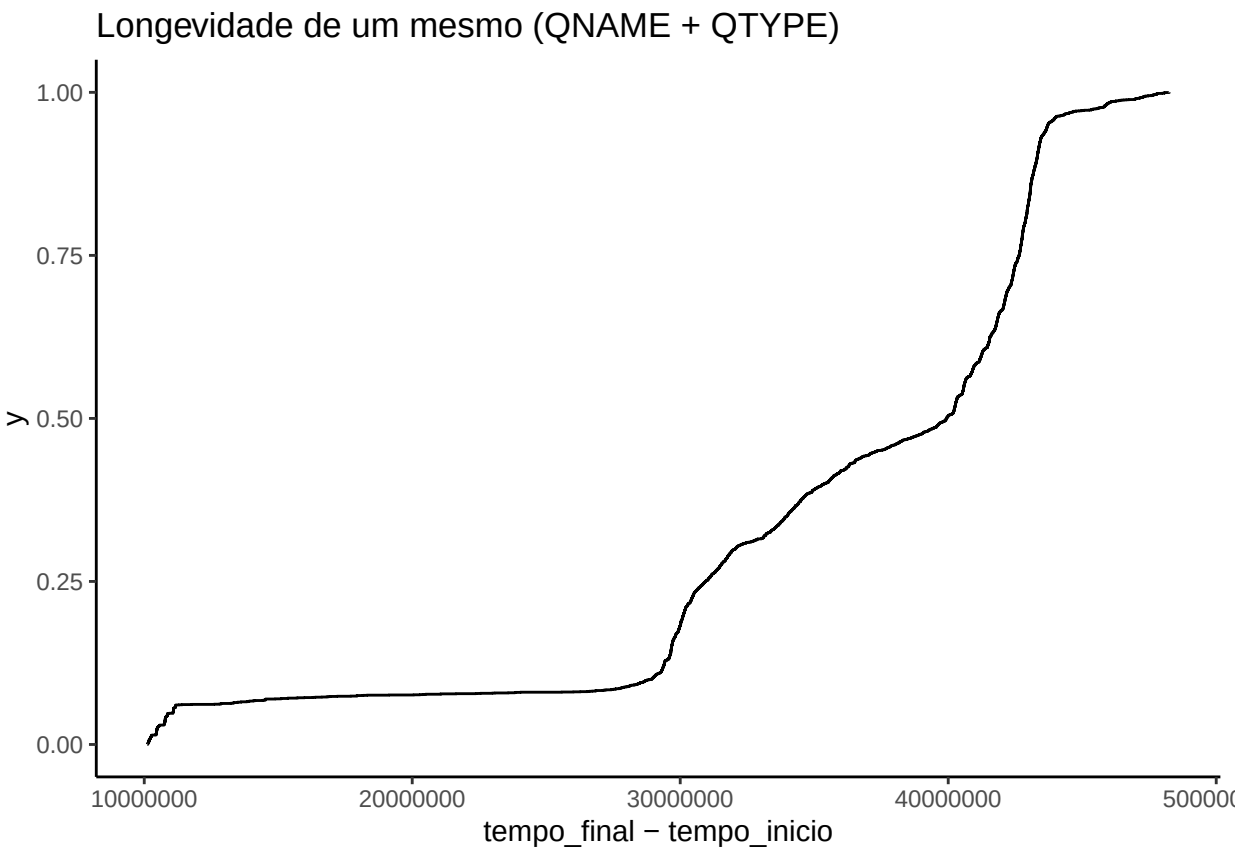


```
percentage_76_secs = quantile(data_grouped$tempo_diff_secs, c(.76))[[1]]
percentage_76_secs/secs_to_days
```

```
## [1] 14.23
```

```
percentage_99_secs = quantile(data_grouped$tempo_diff_secs, c(.995))[[1]]
percentage_99_secs/secs_to_days
```

```
## [1] 529.7
```

```
data_grouped.tempo_diff_secs.max / secs_to_days
```

```
## [1] 558.4
```

- Cerca de 24% dos (QNAME + QTYPE) possuem uma longevidade entre 9 e 16 meses

```
data_grouped %>%
  filter(tempo_diff_secs > percentage_76_secs) %>%
  ggplot(aes(x= tempo_diff_secs / secs_to_days)) +
  geom_histogram(bins = 50, fill='blue', color ='black') +
  ggtitle("Longevidade de um mesmo (QNAME + QTYPE)") +
  xlab("Dias de Longevidade") +
  theme_classic()
```

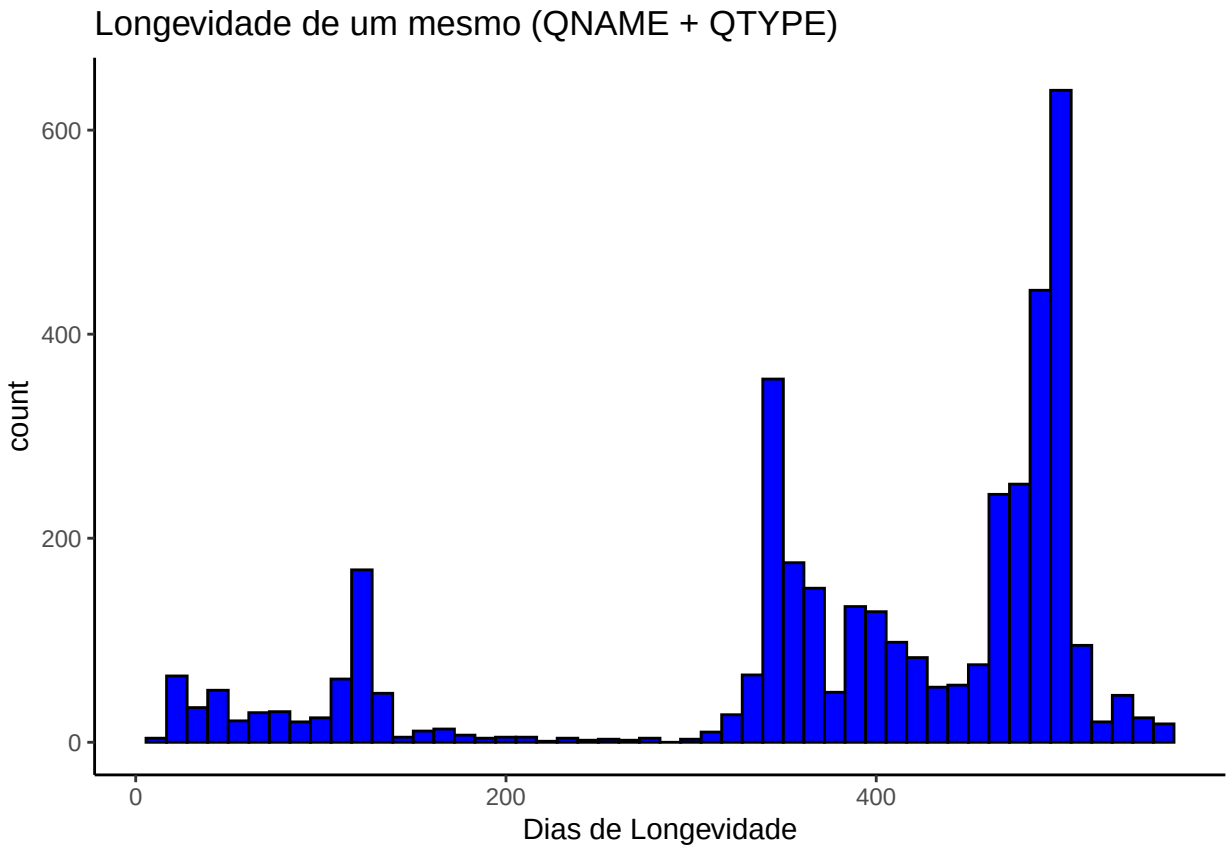


```
data_bigger_than_76 = data_grouped %>%
  filter(tempo_diff_secs > percentage_76_secs) %>%
  ungroup() %>%
  group_by(qtype) %>%
  summarise(qtype_quantity = n()) %>%
  arrange(desc(qtype_quantity))


sum_qtype_quantity = sum(data_bigger_than_76$qtype_quantity)
data_bigger_than_76_percentage = data_bigger_than_76 %>%
  mutate(qtype_quantity_percentage = (qtype_quantity / sum_qtype_quantity) * 100)

data_bigger_than_76_percentage
```

```
## # A tibble: 10 x 3
##    qtype qtype_quantity qtype_quantity_percentage
##    <chr>          <int>                     <dbl>
##  1 A               3079                    79.6
##  2 MX               714                    18.4
##  3 TXT               35                     0.904
##  4 ANY               31                     0.801
##  5 PTR                3                     0.0775
##  6 RRSIG              3                     0.0775
##  7 AAAA               2                     0.0517
##  8 CAA                1                     0.0258
```

```
##  9 NS                1                    0.0258
## 10 SOA               1                    0.0258
```

```
data_bigger_than_76_percentage %>%
 ggplot( aes(x=reorder(qtype, +qtype_quantity_percentage), y=qtype_quantity_percentage, fill=qtype)) +
    geom_bar(stat="identity", position="dodge") +
    scale_fill_viridis(discrete=TRUE, name="") +
    geom_text(aes(label = paste(round(qtype_quantity_percentage, 2), "%")), vjust = -0.10, ) +
    theme_classic() +
    ylab("Porcentagem da quantidade") +
    xlab("QTYPE") +
    ggtitle("QTYPE com longevidade entre 9 e 16 meses")
```

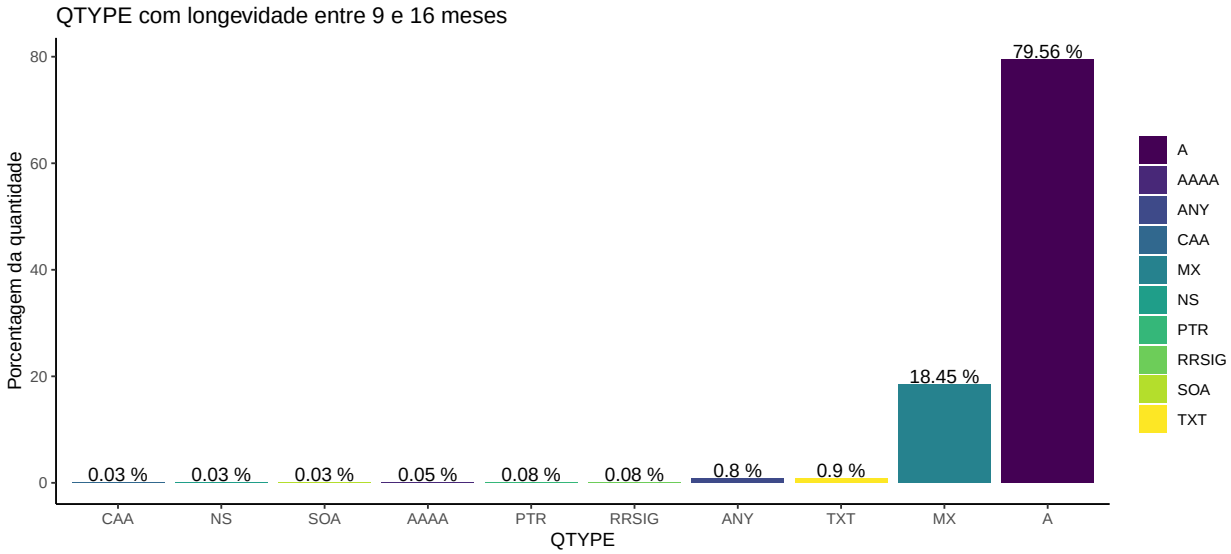

- Então dos QTYPE que possuem uma alta longevidade entre 9 e 16 meses (cerca de 24% de todos os registros 76% ~ 100%)
  - 20% (714) deles possuem o QTYPE "MX"
  - 78% (3079) dos ataques com maior longevidade utilizam o QTYPE "A", o que é surpreendente
  - E por fim o QTYPE "ANY" aparece com apenas 31 registros de QTYPE com longevidade entre 9 e 16 meses

```
percentage_76_secs_A_qnames = data_grouped %>%
  filter(tempo_diff_secs > percentage_76_secs) %>%
  filter(qtype == "A") %>%
  select(qname) %>%
  distinct(qname)


percentage_76_secs_qtype_A = data %>%
  filter(qtype == "A") %>%
  filter(qname %in% percentage_76_secs_A_qnames$qname)
```

- O QTYPE "A" é o QTYPE que possui a maior quantidade de QNAMEs com alta longevidade entre 9 e 16 meses

– Esse é o top 10 de QTYPE A agroupado por QNAME representado por qname_count e somado o request_per_attack

```
percentage_76_secs_qtype_A_group_qname = percentage_76_secs_qtype_A %>%
  group_by(qname) %>%
  summarise(qname_count = n(), sum_requests_per_attack=sum(requests_per_attack),
            tempo_inicio=min(tempo_inicio_cast), tempo_final=max(tempo_final_cast),
            sum_requests_per_attack=sum(requests_per_attack)) %>%
  mutate(tempo_diff_secs = as.numeric(tempo_final - tempo_inicio, units="secs"),
         tempo_diff = tempo_final - tempo_inicio)

percentage_76_secs_qtype_A_group_qname %>%
  arrange(desc(tempo_diff_secs)) %>%
  select('qname', 'qname_count', 'tempo_diff') %>%
  head(25) %>%
  print(n=35)
```

```
## # A tibble: 25 x 3
##    qname                                      qname_count tempo_diff
##    <chr>                                            <int> <drtn>
##  1 200-19-107-238.measure.xiaofengtest.com.            98 556.4 days
##  2 a.gtld-servers.net.                                 84 556.2 days
##  3 public1.114dns.com.                                527 552.2 days
##  4 dnsscan.shadowserver.org.                          111 549.4 days
##  5 amazon.com.                                        454 546.8 days
##  6 direct.shodan.io.                                    4 544.3 days
##  7 whoami.akamai.net.                                5742 543.6 days
##  8 www.bb.com.br.                                      29 538.7 days
##  9 200-19-107-238.app.xiaofengtest.com.               122 533.4 days
## 10 gmail.com.                                          73 532.5 days
## 11 twitter.com.                                        63 532.2 days
## 12 zoom.us.                                            67 532.1 days
## 13 testip.internet-census.org.                         44 532.1 days
## 14 tstng.net.                                          45 531.8 days
## 15 web.whatsapp.com.                                   64 531.7 days
## 16 www.facebook.com.                                   78 531.7 days
## 17 whatsapp.com.                                       71 531.6 days
## 18 www.google.com.                                     86 531.5 days
## 19 aliexpress.com.                                     15 531.3 days
## 20 chase.com.                                           9 531.2 days
## 21 www.paypal.com.                                     47 531.0 days
## 22 nytimes.com.                                        18 530.7 days
## 23 adobe.com.                                          13 530.5 days
## 24 www.bradesco.com.br.                                 8 530.5 days
## 25 office.com.                                         15 530.4 days
```

- Uníca coisa a ressaltar aqui é que o top 1 QNAME “whoami.akamai.net.” que apareceu 3639x e foi o registro com maior longevidade 480 dias, cerca de 16 meses
- Ao ordenar pela soma de requests por ataque o top 10 muda

```
percentage_76_secs_qtype_A_group_qname %>%
  arrange(desc(sum_requests_per_attack)) %>%
```

```
  select('qname', 'qname_count', 'sum_requests_per_attack') %>%
  head(10)
```

```
## # A tibble: 10 x 3
##    qname                                qname_count sum_requests_per_attack
##    <chr>                                      <int>                   <int>
##  1 www.ndnslab.com.                            3357                   39546
##  2 www.ac.my.blastodermic-swimmable.info.      1705                   28843
##  3 www.ac.my.superability-kooka.info.           771                   26210
##  4 admin.asry.net.                               60                   21672
##  5 probe.idealeer.com.                         1108                   13150
##  6 theguardian.webredirect.org.                  62                   12805
##  7 ftp.ebisb.com.                                47                   12035
##  8 dji.gov.ae.                                   63                   11492
##  9 hotspot.accesscam.org.                        52                   11366
## 10 2015annualreport.bloomberg.org.             4264                   10967
```

- Nenhum dos registros ordenados pela quantidade de requisições por ataque está no top 10 ordenado pela longevidade dos dados
- Para verificar se o mesmo query_id é muito utilizado foi agrupado somente por query_id

```
percentage_76_secs_qtype_A %>%
  group_by(query_id) %>%
  summarise(query_id_count = n(), sum_requests_per_attack=sum(requests_per_attack), tempo_inicio=min(ter
  mutate(tempo_diff_secs = as.numeric(tempo_final - tempo_inicio, units="secs"), tempo_diff = tempo_fina
  arrange(desc(query_id_count)) %>%
  select('query_id', 'query_id_count', 'sum_requests_per_attack', 'tempo_diff')  %>%
  head(10)
```

```
## # A tibble: 10 x 4
##    query_id query_id_count sum_requests_per_attack tempo_diff
##       <int>          <int>                   <int> <drtn>
##  1    50265            660                    1487 43886164 secs
##  2    45810            323                     401 41240463 secs
##  3    28826            215                     282 37657765 secs
##  4    64206             99                     102 39524383 secs
##  5     4218             98                     110 34277498 secs
##  6     1337             86                     100 48052505 secs
##  7    44557             76                      83 45752078 secs
##  8    14602             64                     127 16297096 secs
##  9    16028             49                    3793 45945897 secs
## 10    36379             45                     142 14703113 secs
```

- Nada chamou a atenção

- uma análise mais interessante levando os períodos em comparação é a contagem de nomes novos e retirados (i.e., que deixam de ser usados) por período
  - um nome é contado como novo no período da primeira ocorrência do dataset

  - um nome é contado como retirado no período da última ocorrência no dataset

- p.ex., um nome que aparece pela primeira vez em 23/04/21 e pela última em 28/10/21 conta como novo em 2021.Q2 e como retirado em 2021.Q4
- produzir uma tabela e um gráfico de barras (com 2 barras por período, de novos e retirados) com esses dados
- se a quantidade de nomes novos em 2020.Q4 (1o período) for absurdamente maior que a dos demais períodos, considerar a possibilidade de omiti-la do gráfico

```
data_quarters = data_grouped %>%
  mutate(year_period_inicio=paste(year(tempo_inicio), quarters(tempo_inicio), sep = "."),
         year_period_fim=paste(year(tempo_final), quarters(tempo_final), sep = "."))


data_quarters_new = data_quarters %>%
  ungroup() %>%
  count(year_period_inicio, name = "novos")

data_quarters_removed = data_quarters %>%
  ungroup() %>%
  count(year_period_fim, name = "retirados")

data_quarters_new_removed = data_quarters_new %>%
  inner_join(data_quarters_removed, by = c("year_period_inicio" = "year_period_fim")) %>%
  mutate(year_period =  as.factor(year_period_inicio) ) %>%
  select('year_period', 'novos', 'retirados') %>%
  arrange(year_period)

data_quarters_new_removed
```

```
## # A tibble: 7 x 3
##   year_period novos retirados
##   <fct>       <int>     <int>
## 1 2020.Q4      6637      3726
## 2 2021.Q1      1096       430
## 3 2021.Q2       306       618
## 4 2021.Q3       909       902
## 5 2021.Q4      4083      4905
## 6 2022.Q1       945      1440
## 7 2022.Q2      2149      4104
```

```
data_quarters_new_removed %>%
  ggplot( aes(x=year_period, y=novos)) +
  geom_bar(stat="identity", position="dodge", fill = "#00FF00") +
  ggtitle("Novos QNAMES por trimestre") +
  xlab("Período") +
  ylab("Novos - Primeira ocorrência") +
  theme_classic()
```

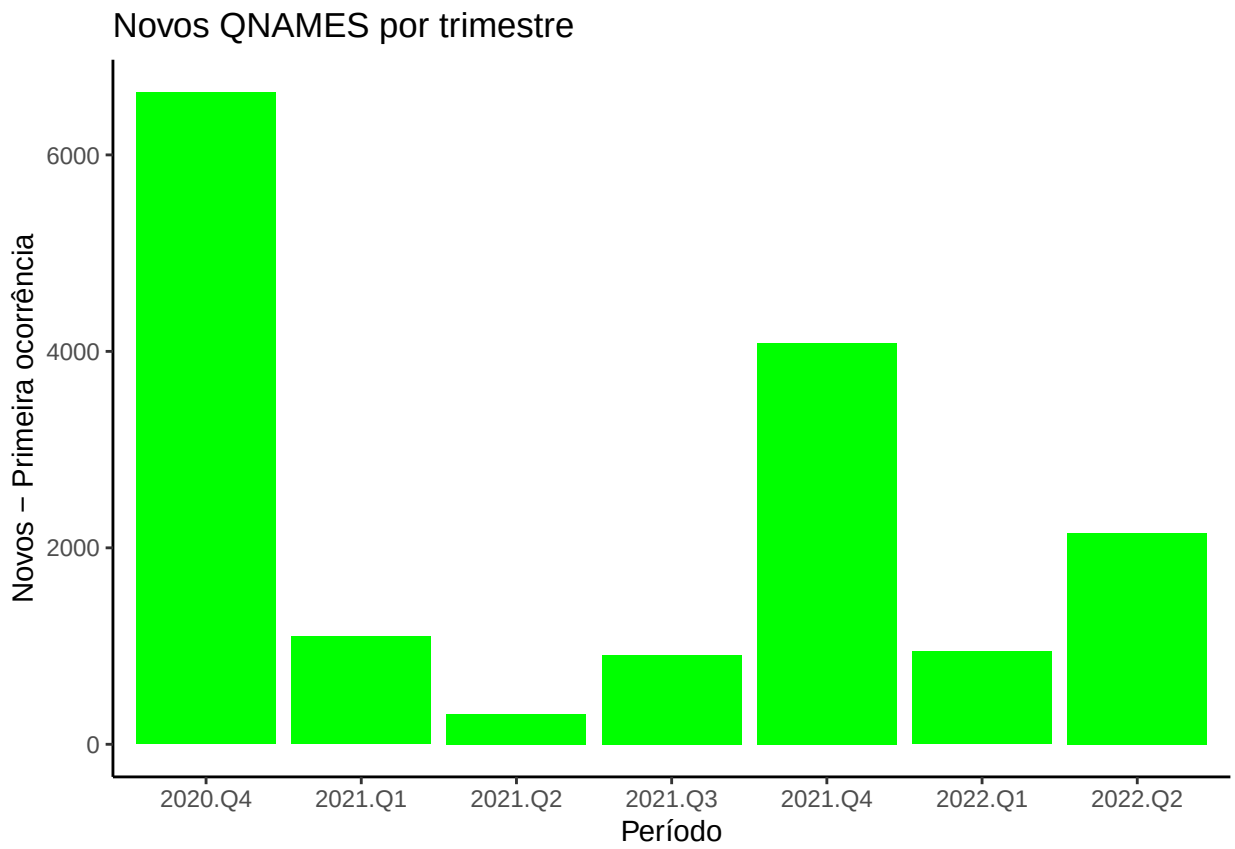


```
data_quarters_new_removed %>%
  ggplot( aes(x=year_period, y=retirados)) +
  geom_bar(stat="identity", position="dodge", fill = "#FF6666") +
  ggtitle("QNAMES retirados por trimestre") +
  xlab("Período") +
  ylab("Retirado - Ultima ocorrência") +
  theme_classic()
```

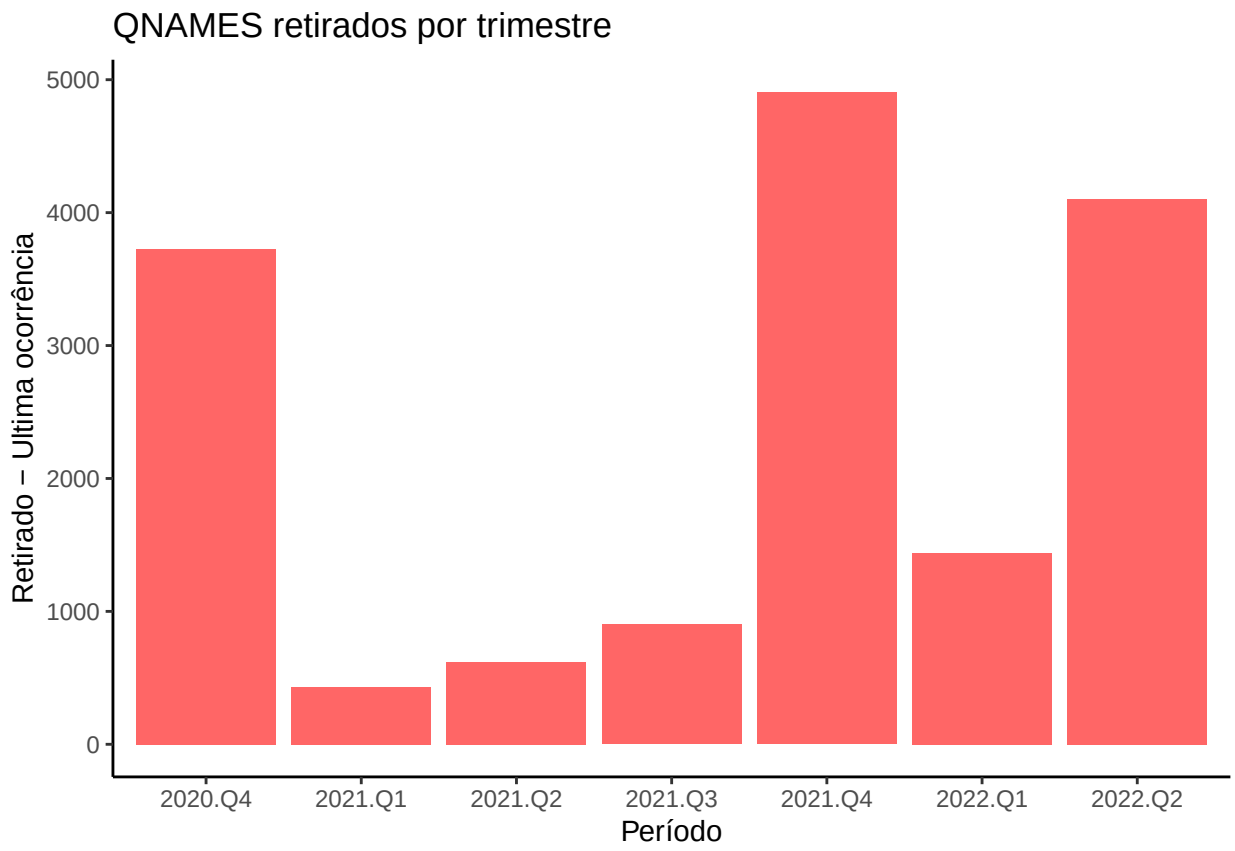

QNAMES Novos/Retirados por trimestre

- Um QNAME é considerado
  - Novo no trimestre em que aparece a primeira vez no database
  - Retirado no trimestre em que aparece pela ultima vez

```
data_quarters_new_removed.st = stack(data_quarters_new_removed)
```

```
## Warning in stack.data.frame(data_quarters_new_removed): non-vector columns will
## be ignored
```

```
data_quarters_new_removed.st$year_period = rep(data_quarters_new_removed$year_period, 2)

data_quarters_new_removed.st %>%
  ggplot( aes(x=year_period, y=values, fill=ind)) +
  geom_bar(stat="identity", position="dodge") +
  ggtitle("QNAMES novos e retirados por trimestre") +
  xlab("Período") +
  ylab("Quantidade") +
  theme_classic()
```

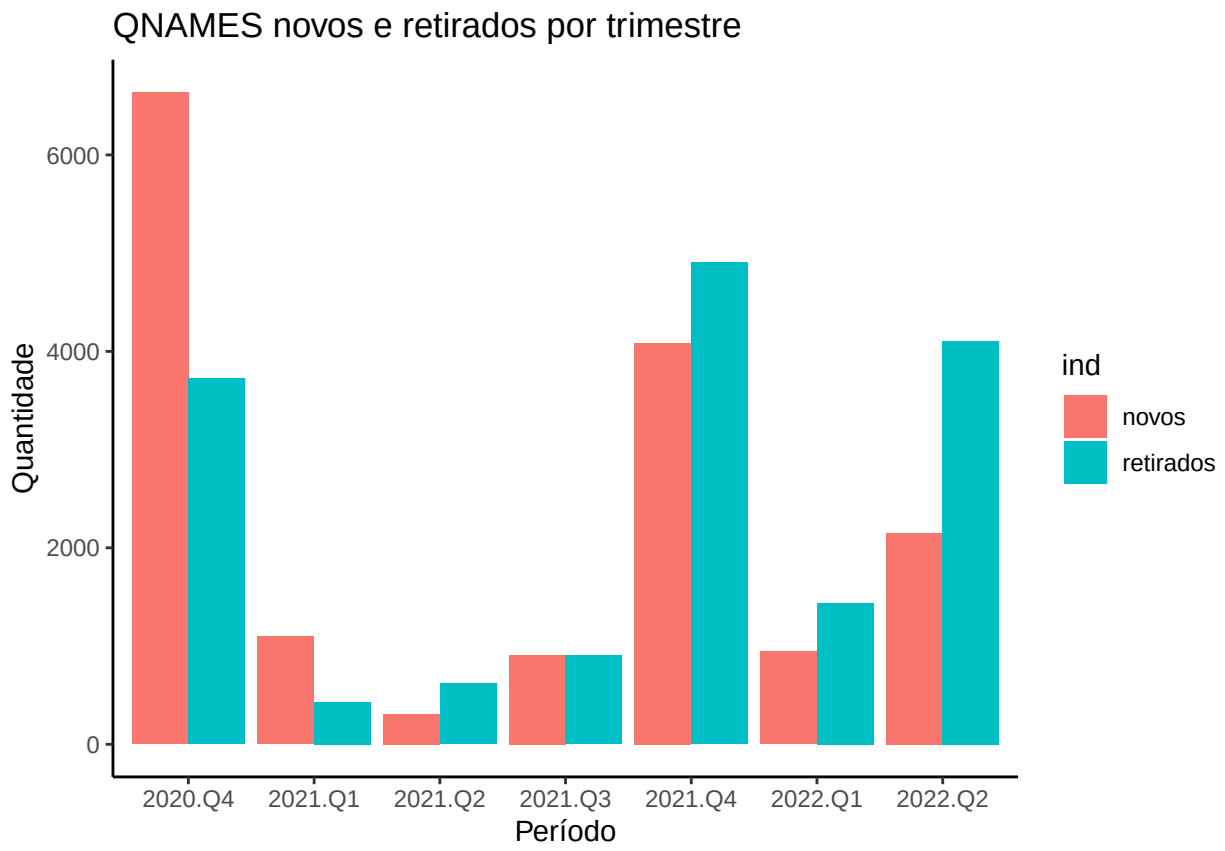

- Contudo, caso um ataque inicie e termine no mesmo trimestre, ele conta como um para novo e um para retirado
- Removendo todos os registros que iniciam e terminam no mesmo trimestre

```
data_different_quarters = data_quarters %>%
  filter(year_period_inicio != year_period_fim)

data_quarters_new2 = data_different_quarters %>%
  ungroup() %>%
  count(year_period_inicio, name = "novos")

data_quarters_removed2 = data_different_quarters %>%
  ungroup() %>%
  count(year_period_fim, name = "retirados")

data_diff_quarters_new_removed = data_quarters_new2 %>%
  inner_join(data_quarters_removed2, by = c("year_period_inicio" = "year_period_fim")) %>%
  mutate(year_period =  as.factor(year_period_inicio) ) %>%
  select('year_period', 'novos', 'retirados') %>%
  arrange(year_period)


data_diff_quarters_new_removed.st = stack(data_diff_quarters_new_removed)
```

```
## Warning in stack.data.frame(data_diff_quarters_new_removed): non-vector columns
```

```
## will be ignored
```

```
data_diff_quarters_new_removed.st$year_period = rep(data_diff_quarters_new_removed$year_period, 2)


data_diff_quarters_new_removed.st %>%
  ggplot( aes(x=year_period, y=values, fill=ind)) +
  geom_bar(stat="identity", position="dodge") +
  ggtitle("Somente QNAMES que iniciam e terminam em trimestres diferentes") +
  xlab("Período") +
  ylab("Quantidade") +
  theme_classic()
```

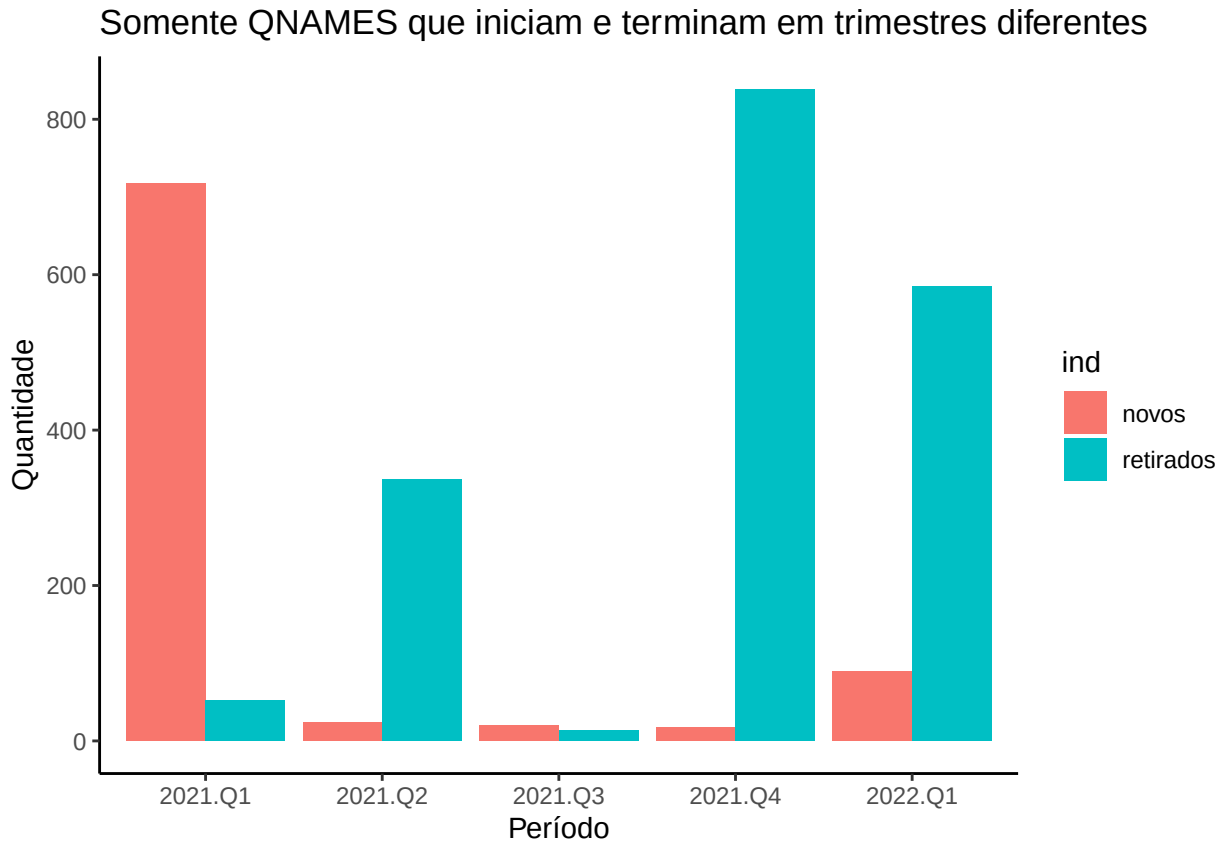

- Dessa forma, foram considerados somente ataques em que iniciaram e finalizaram em trimestres diferentes

- Por curiosidade fui verificar para colocar lado a lado aqueles registros que iniciam e terminam no mesmo trimestre

```
data_same_quarters = data_quarters %>%
  filter(year_period_inicio == year_period_fim)

data_same_quarters = data_quarters %>%
  filter(year_period_inicio == year_period_fim) %>%
  ungroup() %>%
  count(year_period_inicio, name = "mesmo_trimestre") %>%
    mutate(year_period =  as.factor(year_period_inicio) )
```

```r
data_quarters_new_removed_same = data_diff_quarters_new_removed %>%
  inner_join(data_same_quarters, by = c("year_period" = "year_period")) %>%
  mutate(year_period =  as.factor(year_period_inicio) ) %>%
  select('year_period', 'novos', 'retirados', 'mesmo_trimestre') %>%
  arrange(year_period)


data_quarters_new_removed_same.st = stack(data_quarters_new_removed_same)
```

```
## Warning in stack.data.frame(data_quarters_new_removed_same): non-vector columns
## will be ignored
```

```r
data_quarters_new_removed_same.st$year_period = rep(data_quarters_new_removed_same$year_period, 3)


data_quarters_new_removed_same.st %>%
  ggplot( aes(x=year_period, y=values, fill=ind)) +
  geom_bar(stat="identity", position="dodge") +
  ggtitle("QNAMES novos/retirados/(nasceram e morreram no mesmo trimestre)  por trimestres") +
  xlab("Período") +
  ylab("Quantidade") +
  theme_classic()
```

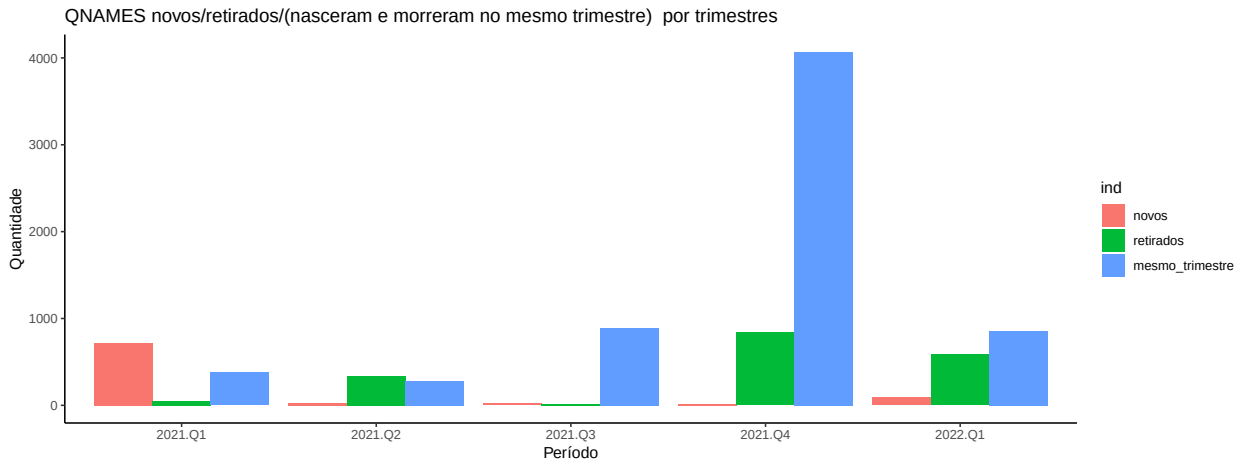

- A barra azul então representa que no último trimestre de 2021, tiveram 4066 QNAMES que naceram e morreram no mesmo período
- Média de requisições por ataque
  - A soma de todos os requests dos ataques agrupados por (QNAME+QTYPE) / divido pela quantidade de ataques
  - Uma observação aqui é que muitos ataques que possuem uma média alta de requisições por ataque são aqueles em que tiveram apenas um ataque

```
data_quarters %>%
  ungroup() %>%
  arrange(desc(avg_requests_per_attack)) %>%
  select(avg_requests_per_attack, number_of_attacks, sum_requests_per_attack) %>%
  print(n=15)
```

```
## # A tibble: 16,125 x 3
##    avg_requests_per_attack number_of_attacks sum_requests_per_attack
##                      <dbl>             <int>                   <int>
##  1                   18556                25                  463905
##  2                   10499                 2                   20998
##  3                    8467                 1                    8467
##  4                    4953                 1                    4953
##  5                    4537                 1                    4537
##  6                    2794                 1                    2794
##  7                    2222                 1                    2222
##  8                    2026                 1                    2026
##  9                    1830                 1                    1830
## 10                    1702                 1                    1702
## 11                    1544                 4                    6176
## 12                    1485                 1                    1485
## 13                    1462                 1                    1462
## 14                    1395                 1                    1395
## 15                    1220                 4                    4883
## # ... with 16,110 more rows
```

```
quantile(data_quarters$avg_requests_per_attack, trim=trim_value)
```

```
##    0%   25%   50%   75%  100%
##     1     2     8    21 18556
```

- Média de ataques por dia
  - A média de ataques por dia, foi mensurado contando a quantidade de ataques (number_of_attacks) e dividindo pelo número de dias entre a data inicio e fim dos ataques de um (QNAME+QTYPE)

```
data_quarters_avg_attacks = data_quarters %>%
  ungroup() %>%
  mutate(tempo_diff_days=as.numeric(trunc(difftime(tempo_final, tempo_inicio, units = "days")))) %>%
  filter(tempo_diff_days > 1) %>%
  mutate(avg_attacks_per_day=trunc(number_of_attacks/tempo_diff_days))

data_quarters_avg_attacks %>%
  arrange(desc(avg_attacks_per_day)) %>%
  select(avg_attacks_per_day, avg_requests_per_attack, number_of_attacks, tempo_diff_days) %>%
  print(n=15)
```

```
## # A tibble: 3,946 x 4
##    avg_attacks_per_day avg_requests_per_attack number_of_attacks tempo_diff_days
##                  <dbl>                   <dbl>             <int>           <dbl>
##  1                5512                      16             49615               9
```

```
##  2                359                  28            56479            157
##  3                257                  26            45523            177
##  4                212                 614           118333            556
##  5                111                  45            58009            519
##  6                 55                 196            30375            544
##  7                 47                   1              143              3
##  8                 43                   1               87              2
##  9                 40                   2              121              3
## 10                 38                   1              193              5
## 11                 37                   1              187              5
## 12                 37                   1              112              3
## 13                 29                  13              145              5
## 14                 28                  13               84              3
## 15                 25                  11             3357            130
## # ... with 3,931 more rows
```

```
data_quarters_avg_attacks.count = data_quarters_avg_attacks %>%
  count(avg_attacks_per_day, name = "number_of_qnames") %>%
  arrange(desc(number_of_qnames))

data_quarters_avg_attacks.count %>%
  print(n=10)
```

```
## # A tibble: 32 x 2
##    avg_attacks_per_day number_of_qnames
##                  <dbl>            <int>
##  1                   0             3868
##  2                   1               21
##  3                   2               10
##  4                   4                6
##  5                   3                4
##  6                  17                4
##  7                  12                3
##  8                  16                3
##  9                   5                2
## 10                  15                2
## # ... with 22 more rows
```

```
quantile(
  data_quarters_avg_attacks$avg_attacks_per_day[data_quarters_avg_attacks$avg_attacks_per_day>0],
  trim=trim_value
)
```

```
##      0%     25%     50%     75%    100%
##    1.00    1.00    4.00   17.75 5512.00
```

- Em 3.868 QNAMES a média de ataques por dia é 0, 78.75 % dos registros
- mas em 25% dos QNAMES possuem uma média de mais de 17 ataques por dia

```
data_quarters_avg_attacks %>%
  ggplot(aes(x= avg_attacks_per_day)) +
  stat_ecdf(geom = "step", pad = FALSE) +
```

```
ggtitle("Quantidade de ataques diários de um mesmo (QNAME + QTYPE)") +
xlab("Quantidade de ataques") +
theme_classic()
```