DN2. DNS: longevidade de nomes

Rafilx

2022-05-02

```
##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
##     filter, lag

## The following objects are masked from 'package:base':
##
##     intersect, setdiff, setequal, union

## Loading required package: viridisLite

##
## Attaching package: 'lubridate'

## The following objects are masked from 'package:base':
##
##     date, intersect, setdiff, union
```

R Markdown

A longevidade de um nome (QNAME+QTYPE) no dataset pode ser definida como o intervalo entre a primeira e a última aparição desse nome. Calcular a longevidade dos nomes no dataset, e analisar como essa variável está distribuída.

Resultados esperados:

- análise gráfica da distribuição (histograma, ECDF) e numérica (min, max, média, mediana) da longevidade dos nomes
  - por enquanto não vejo sentido em dividir a análise por período, então pode considerar o dataset como um todo
  - minha intuição é que a distribuição seja assimétrica com (longa) cauda à direita
- Busca os dados no banco com o parse do DNS ja realizado, então temos:
  - qname que é o domínio
  - QTYPE tipo da query
  - query_id ID da transação definido pelo atacante
  - year_period ano e trimestre em que ocorreu o ataque exemplo "20212" o ataque ocorreu no segundo trimestre do 2021

```
db <- dbConnect(RSQLite::SQLite(), dbname="../dnstor_statistics_dns.sqlite")

data_unfetch <-dbSendQuery(db, "
  SELECT *, CAST(CAST(year AS text) || CAST(period AS text) as integer) as year_period
    FROM DNS_ANALYSIS
        JOIN DNS_ANALYSIS_QUESTION
          ON DNS_ANALYSIS.id = DNS_ANALYSIS_QUESTION.dns_analysis_id
     WHERE QTYPE != 0
")
data <- fetch(data_unfetch)

dbDisconnect(db)
```

```
## Warning in connection_release(conn@ptr): There are 1 result in use. The
## connection will be released when they are closed
```

```
data['tempo_final_cast'] = as.POSIXct(data[['tempo_final']], format = "%Y-%m-%d %H:%M:%S")
data['tempo_inicio_cast'] = as.POSIXct(data[['tempo_inicio']], format = "%Y-%m-%d %H:%M:%S")

secs_to_month = (60 * 60 * 24 * 30)

data_grouped = data %>%
  group_by(qname, qtype) %>%
  summarise(tempo_inicio=min(tempo_inicio_cast), tempo_final=max(tempo_final_cast), sum_requests_per_at
  mutate(tempo_diff_secs = as.numeric(tempo_final - tempo_inicio, units="secs"), tempo_diff = tempo_fina
  #filter(tempo_diff > 0) %>%
  arrange(desc(tempo_diff_secs))
```

```
## `summarise()` has grouped output by 'qname'. You can override using the
## `.groups` argument.
```

```
data_grouped %>%
  head(10)
```

```
## # A tibble: 10 x 7
## # Groups:   qname [10]
##    qname          qtype tempo_inicio        tempo_final         sum_requests_pe~
##    <chr>          <chr> <dttm>              <dttm>                         <int>
##  1 VERSION.BIND.  TXT   2020-10-30 02:39:27 2022-02-24 08:33:01             5943
##  2 whoami.akamai~ A     2020-10-30 12:33:16 2022-02-23 10:35:19             3885
##  3 com.           ANY   2020-10-31 11:38:32 2022-02-24 09:16:50              478
##  4 version.bind.  TXT   2020-11-01 04:46:10 2022-02-24 15:42:17              592
##  5 isc.org.       ANY   2020-11-01 22:40:23 2022-02-24 02:25:52          2652144
##  6 researchscan5~ A     2020-11-01 15:23:29 2022-02-23 14:06:13              147
##  7 adsports.ae.   MX    2020-11-03 10:59:02 2022-02-23 23:36:50             2452
##  8 public1.114dn~ A     2020-11-04 09:47:54 2022-02-24 15:42:14             1764
##  9 238.107.19.20~ PTR   2020-11-01 23:58:38 2022-02-21 13:45:36              627
## 10 a.gtld-server~ A     2020-10-30 02:55:07 2022-02-18 00:20:55               78
## # ... with 2 more variables: tempo_diff_secs <dbl>, tempo_diff <drtn>
```

```
data_grouped %>%
  ggplot(aes(x= tempo_diff_secs)) +
  geom_histogram(bins = 10, fill='blue', color ='black') +
  ggtitle("Longevidade de um mesmo (QNAME + QTYPE)") +
  xlab("tempo_final - tempo_inicio") +
  theme_classic()
```

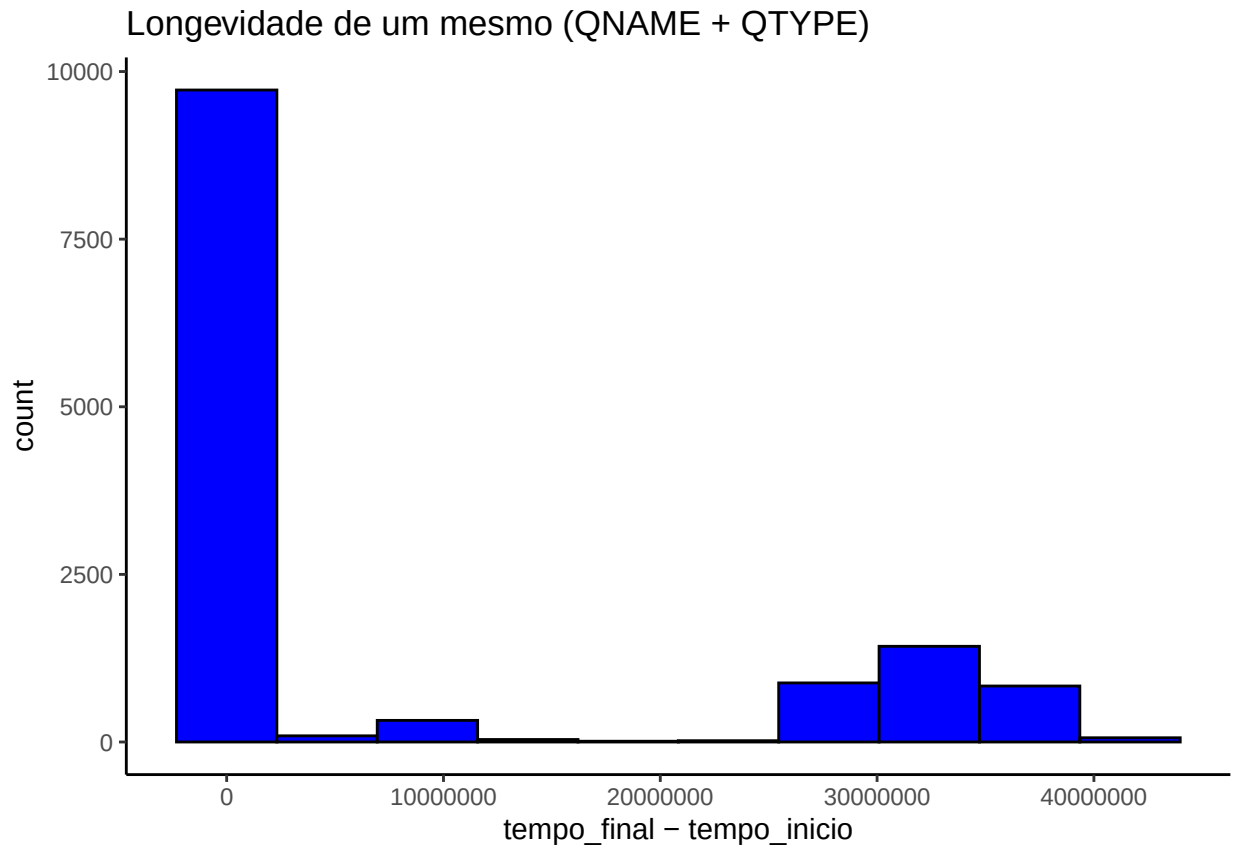


```
data_grouped %>%
  ggplot(aes(x= tempo_diff_secs)) +
  stat_ecdf(geom = "step", pad = FALSE) +
  ggtitle("Longevidade de um mesmo (QNAME + QTYPE)") +
  xlab("tempo_final - tempo_inicio") +
  theme_classic()
```

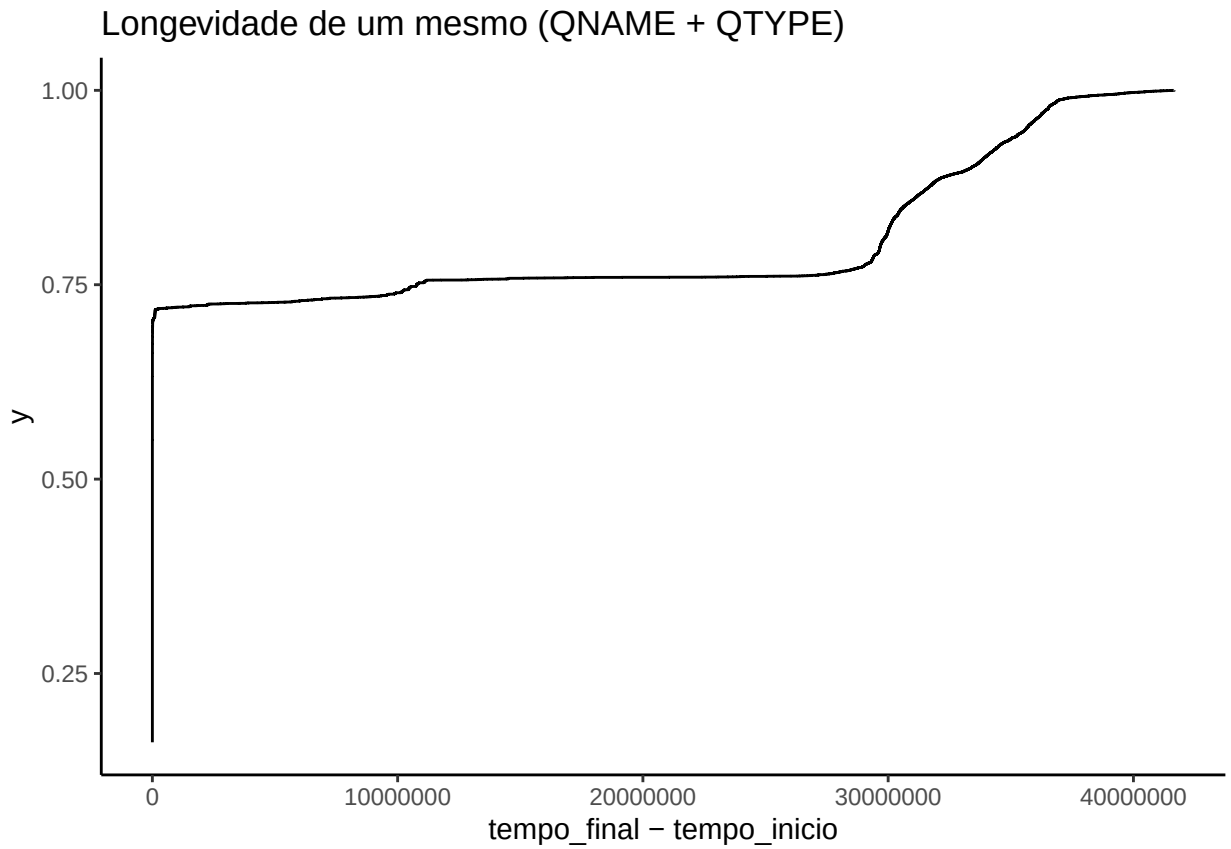


```
data_grouped.tempo_diff_secs.min = min(data_grouped$tempo_diff_secs)
data_grouped.tempo_diff_secs.max = max(data_grouped$tempo_diff_secs)
data_grouped.tempo_diff_secs.mean = mean(data_grouped$tempo_diff_secs)
data_grouped.tempo_diff_secs.median = median(data_grouped$tempo_diff_secs)

quantile(data_grouped$tempo_diff_secs)
```

```
##       0%      25%      50%      75%     100%
##        0       14       69 10780940 41666014
```

```
summary(data_grouped)
```

```
##     qname              qtype            tempo_inicio
##  Length:13411       Length:13411       Min.   :2020-10-29 16:15:05
##  Class :character   Class :character   1st Qu.:2020-12-13 09:03:49
##  Mode  :character   Mode  :character   Median :2021-01-01 02:01:27
##                                        Mean   :2021-04-27 18:46:19
##                                        3rd Qu.:2021-10-25 18:19:09
##                                        Max.   :2022-02-24 15:42:16
##   tempo_final                  sum_requests_per_attack tempo_diff_secs
##  Min.   :2020-10-29 23:17:13   Min.   :       1        Min.   :       0
##  1st Qu.:2020-12-15 00:54:54   1st Qu.:       3        1st Qu.:      14
##  Median :2021-10-25 06:53:39   Median :      12        Median :      69
##  Mean   :2021-07-31 07:23:43   Mean   :    6638        Mean   : 8167044
```

```
##  3rd Qu.:2021-12-06 22:50:36   3rd Qu.:     161        3rd Qu.:10780940
##  Max.   :2022-02-24 15:49:24   Max.   :72346023        Max.   :41666014
##   tempo_diff
##  Length:13411
##  Class :difftime
##  Mode  :numeric
##
##
##
```

- Dados sobre o intervalo entre a primeira e a última aparição desse (QNAME+QTYPE)
  - Mínimo 0 segundos
  - Máximo 16.0749 meses
  - Média 136117.3974 minutos
  - Mediana 69 segundos

```
trim_value = .30

data_grouped.tempo_diff_secs.min = min(data_grouped$tempo_diff_secs, trim=trim_value)
data_grouped.tempo_diff_secs.max = max(data_grouped$tempo_diff_secs, trim=trim_value)
data_grouped.tempo_diff_secs.mean = mean(data_grouped$tempo_diff_secs, trim=trim_value)
data_grouped.tempo_diff_secs.median = median(data_grouped$tempo_diff_secs, trim=trim_value)

quantile(data_grouped$tempo_diff_secs, trim=trim_value)
```

```
##       0%      25%      50%      75%     100%
##        0       14       69 10780940 41666014
```

```
summary(data_grouped, trim=trim_value)
```

```
##     qname              qtype            tempo_inicio
##  Length:13411       Length:13411       Min.   :2020-10-29 16:15:05
##  Class :character   Class :character   1st Qu.:2020-12-13 09:03:49
##  Mode  :character   Mode  :character   Median :2021-01-01 02:01:27
##                                        Mean   :2021-04-27 18:46:19
##                                        3rd Qu.:2021-10-25 18:19:09
##                                        Max.   :2022-02-24 15:42:16
##   tempo_final                  sum_requests_per_attack tempo_diff_secs
##  Min.   :2020-10-29 23:17:13   Min.   :       1        Min.   :       0
##  1st Qu.:2020-12-15 00:54:54   1st Qu.:       3        1st Qu.:      14
##  Median :2021-10-25 06:53:39   Median :      12        Median :      69
##  Mean   :2021-07-31 07:23:43   Mean   :    6638        Mean   : 8167044
##  3rd Qu.:2021-12-06 22:50:36   3rd Qu.:     161        3rd Qu.:10780940
##  Max.   :2022-02-24 15:49:24   Max.   :72346023        Max.   :41666014
##   tempo_diff
##  Length:13411
##  Class :difftime
##  Mode  :numeric
##
##
##
```

- Dados sobre o intervalo entre a primeira e a última aparição do (QNAME+QTYPE) removendo 30% dos valores máximos e mínimos
  - Mínimo 0 segundos
  - Máximo 16.0749 meses
  - Média 12.7382 minutos
  - Mediana 69 segundos
- Identificar qual é o percentil em que há essa mudança de tendência (próximo aos 72-73%) e qual a duração correspondente

```
quantile(data_grouped$tempo_diff_secs,
         c(.5332, .6235, .696282, .710307, .72, .7204,
           .721090026, .73, .7396902445, .75, .76,
           .77, .78, .99))
```

```
##   53.32%   62.35%   69.63%   71.03%      72%   72.04%   72.11%      73%
##      100     1000    10000   100000   598289   803076  1000000  6310057
##   73.97%      75%      76%      77%      78%      99%
## 10000000 10780940 23306177 28575350 29310516 37308538
```

- Isso representa que Y% dos (QNAME+TYPE), tem os seus ataques com duração de até X segundos:
  - 53.3% até 100 segundos
  - 62.3% até 1000 segundos
  - 69.6% até 10000 segundos
  - 71% até 100000 segundos
  - 72% até 598289 segundos
  - 72.04% até 803076 segundos
  - 72.11% até 1000000 segundos
  - 73.97% até 10000000 segundos
- Significa que após os 69% o tempo dos ataques cresce muito até cerca de 73.97% onde estabiliza próximo dos 10000000 segundos
- Uma representação ECDF removendo os registros abaixo da quantidade de segundos em que apresenta estabilidade (10000000 segundos)
  - Possívelmente apresenta uma distribuição assimétrica com cauda a direita

```
data_grouped %>%
  filter(tempo_diff_secs > 10000000) %>%
  ggplot(aes(x= tempo_diff_secs)) +
  stat_ecdf(geom = "step", pad = FALSE) +
  ggtitle("Longevidade de um mesmo (QNAME + QTYPE)") +
  xlab("tempo_final - tempo_inicio") +
  theme_classic()
```

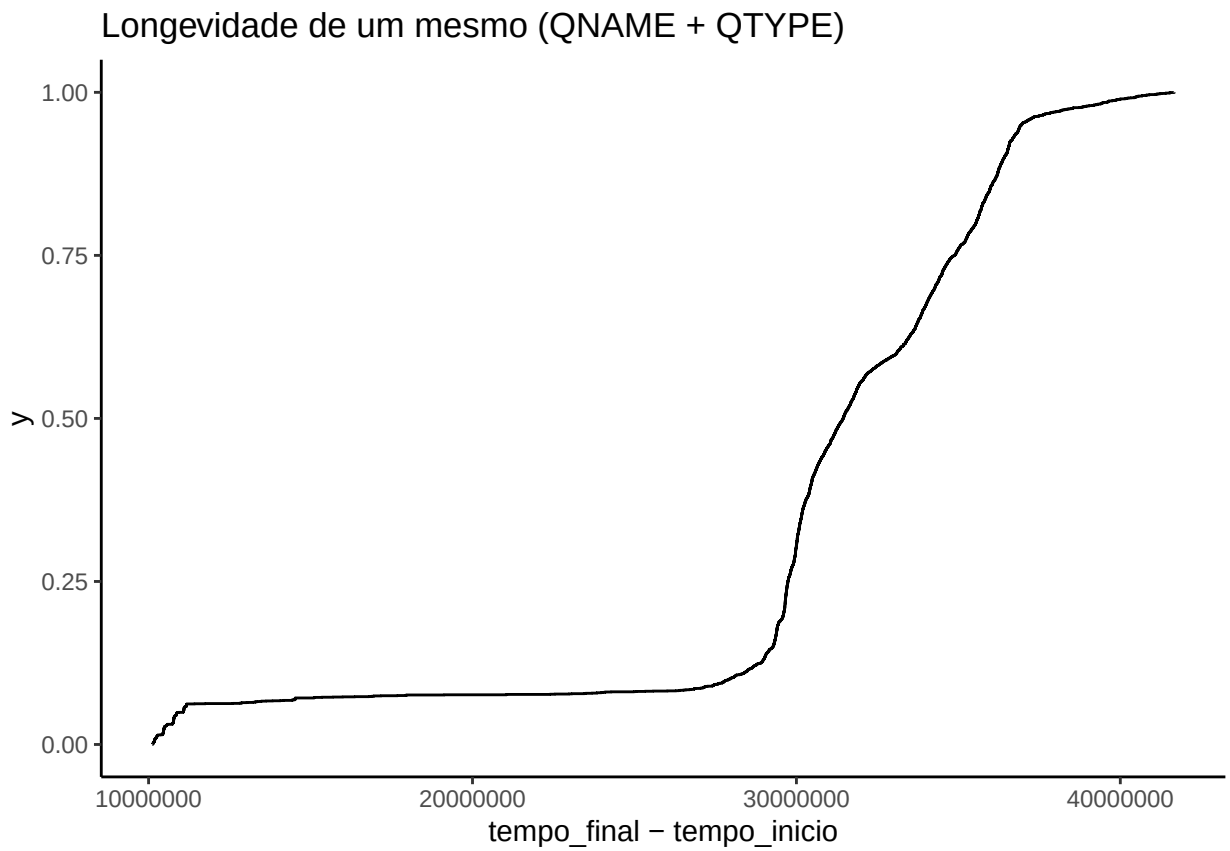


```
percentage_76_secs = quantile(data_grouped$tempo_diff_secs, c(.76))[[1]]
percentage_76_secs/secs_to_month
```

```
## [1] 8.992
```

```
percentage_99_secs = quantile(data_grouped$tempo_diff_secs, c(.995))[[1]]
percentage_99_secs/secs_to_month
```

```
## [1] 15.12
```

```
data_grouped.tempo_diff_secs.max / secs_to_month
```

```
## [1] 16.07
```

- Cerca de 24% dos (QNAME + QTYPE) possuem uma longevidade entre 9 e 16 meses

```
data_grouped %>%
  filter(tempo_diff_secs > percentage_76_secs) %>%
  ggplot(aes(x= tempo_diff_secs / secs_to_month)) +
  geom_histogram(bins = 50, fill='blue', color ='black') +
  ggtitle("Longevidade de um mesmo (QNAME + QTYPE)") +
  xlab("Meses de Longevidade") +
  theme_classic()
```

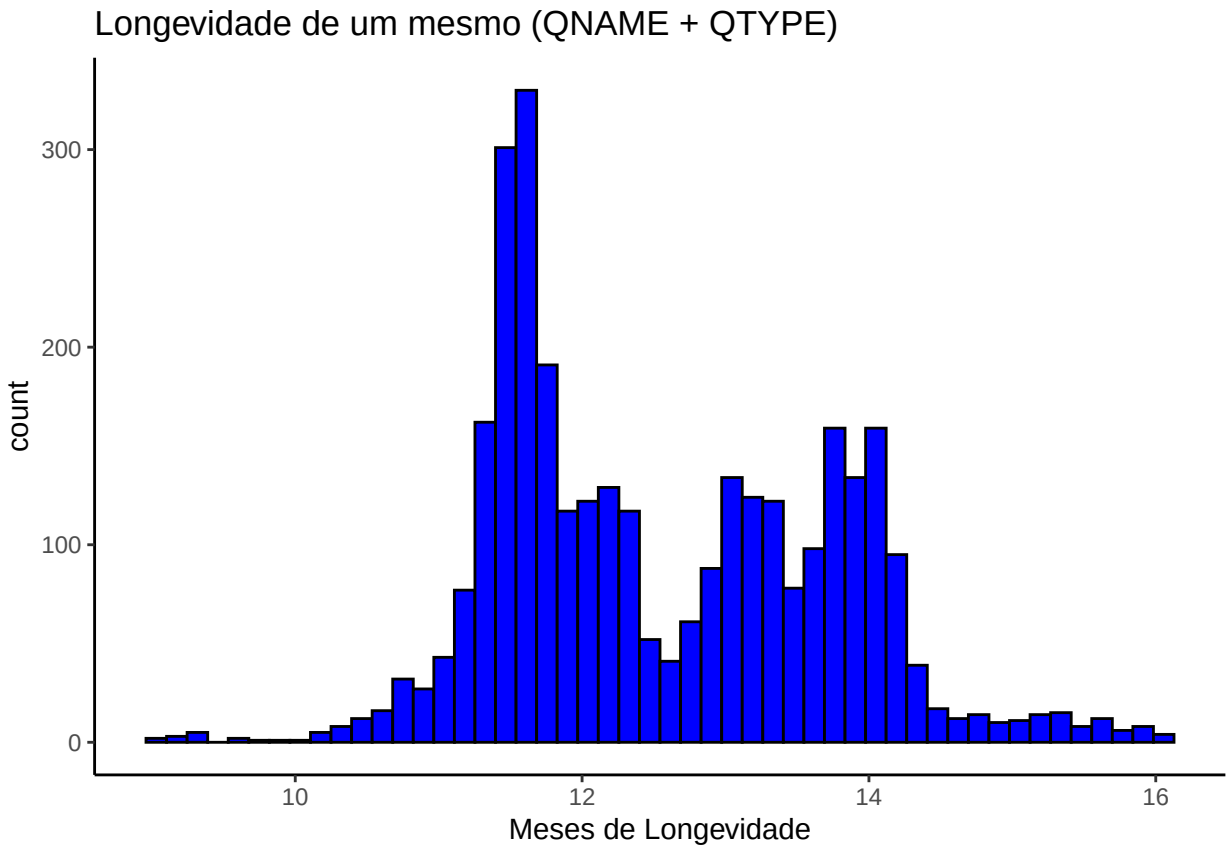


```
data_bigger_than_76 = data_grouped %>%
  filter(tempo_diff_secs > percentage_76_secs) %>%
  ungroup() %>%
  group_by(qtype) %>%
  summarise(qtype_quantity = n()) %>%
  arrange(desc(qtype_quantity))


sum_qtype_quantity = sum(data_bigger_than_76$qtype_quantity)
data_bigger_than_76_percentage = data_bigger_than_76 %>%
  mutate(qtype_quantity_percentage = (qtype_quantity / sum_qtype_quantity) * 100)

data_bigger_than_76_percentage
```

```
## # A tibble: 8 x 3
##   qtype qtype_quantity qtype_quantity_percentage
##   <chr>          <int>                     <dbl>
## 1 A               2516                    78.2
## 2 MX               653                    20.3
## 3 TXT               33                     1.03
## 4 ANY               12                     0.373
## 5 PTR                2                     0.0621
## 6 AAAA               1                     0.0311
## 7 NS                 1                     0.0311
## 8 RRSIG              1                     0.0311
```

```
data_bigger_than_76_percentage %>%
 ggplot( aes(x=reorder(qtype, +qtype_quantity_percentage), y=qtype_quantity_percentage, fill=qtype)) +
    geom_bar(stat="identity", position="dodge") +
    scale_fill_viridis(discrete=TRUE, name="") +
    geom_text(aes(label = paste(round(qtype_quantity_percentage, 2), "%")), vjust = -0.10, ) +
    theme_classic() +
    ylab("Porcentagem da quantidade") +
    xlab("QTYPE") +
    ggtitle("QTYPE com longevidade entre 9 e 16 meses")
```

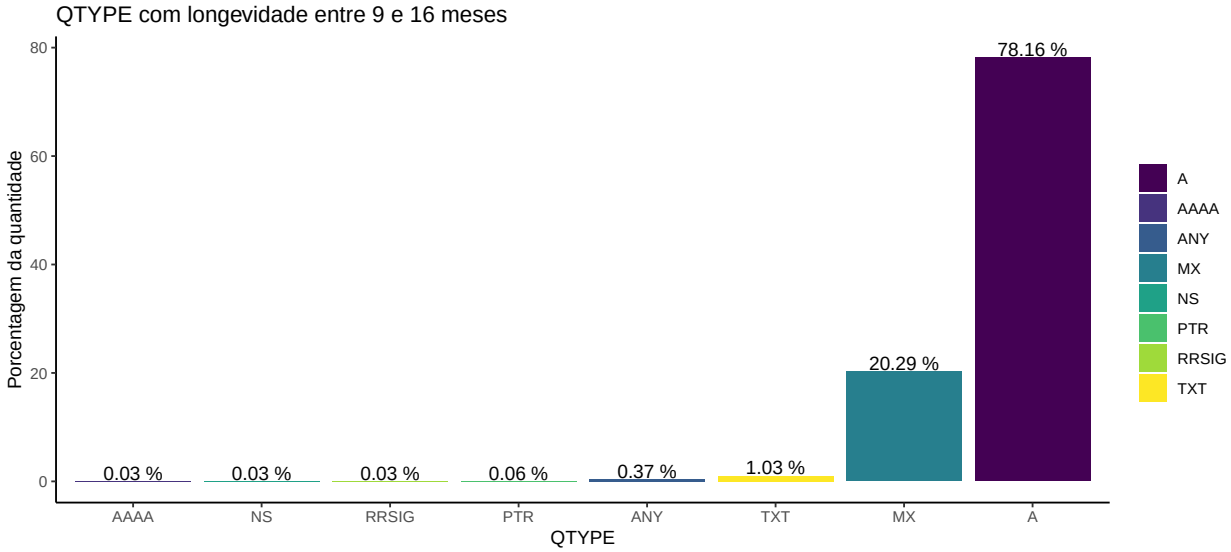

- Então dos QTYPE que possuem uma alta longevidade entre 9 e 16 meses (cerca de 24% de todos os registros 76% ~ 100%)
  - 20% (653) deles possuem o QTYPE "MX"
  - 78% (2516) dos ataques com maior longevidade utilizam o QTYPE "A", o que é surpreendente
  - E por fim o QTYPE "ANY" aparece com apenas 12 registros de QTYPE com longevidade entre 9 e 16 meses

```
percentage_76_secs_A_qnames = data_grouped %>%
  filter(tempo_diff_secs > percentage_76_secs) %>%
  filter(qtype == "A") %>%
  select(qname) %>%
  distinct(qname)


percentage_76_secs_qtype_A = data %>%
  filter(qtype == "A") %>%
  filter(qname %in% percentage_76_secs_A_qnames$qname)
```

- O QTYPE "A" é o QTYPE que possui a maior quantidade de QNAMEs com alta longevidade entre 9 e 16 meses
  - Esse é o top 10 de QTYPE A agroupado por QNAME representado por qname_count e somado o request_per_attack

```r
percentage_76_secs_qtype_A_group_qname = percentage_76_secs_qtype_A %>%
  group_by(qname) %>%
  summarise(qname_count = n(), sum_requests_per_attack=sum(requests_per_attack), tempo_inicio=min(tempo_
  mutate(tempo_diff_secs = as.numeric(tempo_final - tempo_inicio, units="secs"), tempo_diff = tempo_fina

percentage_76_secs_qtype_A_group_qname %>%
  arrange(desc(tempo_diff_secs)) %>%
  head(10)
```

```
## # A tibble: 10 x 7
##    qname    qname_count sum_requests_pe~ tempo_inicio        tempo_final
##    <chr>          <int>            <int> <dttm>              <dttm>
##  1 whoami.~        3639             3885 2020-10-30 12:33:16 2022-02-23 10:35:19
##  2 researc~         143              147 2020-11-01 15:23:29 2022-02-23 14:06:13
##  3 public1~         479             1764 2020-11-04 09:47:54 2022-02-24 15:42:14
##  4 a.gtld-~          73               78 2020-10-30 02:55:07 2022-02-18 00:20:55
##  5 dnsscan~          67               71 2020-11-05 15:30:18 2022-02-22 00:35:12
##  6 amazon.~         433             2014 2020-11-10 15:16:10 2022-02-24 06:20:17
##  7 www.bb.~          24               51 2020-11-05 15:04:15 2022-02-17 15:57:08
##  8 www.bai~          17               28 2020-11-11 03:58:33 2022-02-19 11:34:15
##  9 www.goo~          13               40 2020-11-19 09:44:27 2022-02-23 13:34:35
## 10 www.bra~           5                5 2020-11-13 22:09:40 2022-02-17 16:27:09
## # ... with 2 more variables: tempo_diff_secs <dbl>, tempo_diff <drtn>
```

- Uníca coisa a ressaltar aqui é que o top 1 QNAME "whoami.akamai.net." que apareceu 3639x e foi o registro com maior longevidade 480 dias, cerca de 16 meses
- Ao ordenar pela soma de requests por ataque o top 10 muda

```r
percentage_76_secs_qtype_A_group_qname %>%
  arrange(desc(sum_requests_per_attack)) %>%
  head(10)
```

```
## # A tibble: 10 x 7
##    qname    qname_count sum_requests_pe~ tempo_inicio        tempo_final
##    <chr>          <int>            <int> <dttm>              <dttm>
##  1 admin.a~          50            21565 2020-12-28 05:54:53 2022-01-29 06:11:28
##  2 theguar~          58            12731 2021-02-07 10:19:59 2022-02-24 11:15:23
##  3 ftp.ebi~          40            11840 2020-12-25 00:28:07 2022-02-18 08:57:08
##  4 dji.gov~          57            11246 2020-12-27 01:14:12 2022-02-23 13:30:12
##  5 hotspot~          44            11004 2021-02-07 10:19:50 2021-12-31 16:37:20
##  6 emarata~          50             9447 2020-12-20 06:29:54 2021-12-12 02:55:22
##  7 vpn.qat~          44             6651 2021-01-04 10:52:05 2022-02-09 23:24:32
##  8 moi.gov~          43             6280 2021-01-01 14:29:59 2022-01-16 07:14:32
##  9 tmall.c~          13             5625 2020-11-25 10:50:33 2022-01-28 09:18:56
## 10 vr1.myn~          50             4896 2020-12-28 14:22:21 2022-02-08 23:01:33
## # ... with 2 more variables: tempo_diff_secs <dbl>, tempo_diff <drtn>
```

- Nenhum dos registros ordenados pela quantidade de requisições por ataque está no top 10 ordenado pela longevidade dos dados
- Para verificar se o mesmo query_id é muito utilizado foi agrupado somente por query_id

```
percentage_76_secs_qtype_A %>%
  group_by(query_id) %>%
  summarise(query_id_count = n(), sum_requests_per_attack=sum(requests_per_attack), tempo_inicio=min(te
  mutate(tempo_diff_secs = as.numeric(tempo_final - tempo_inicio, units="secs"), tempo_diff = tempo_fin
  arrange(desc(query_id_count)) %>%
  head(10)
```

```
## # A tibble: 10 x 7
##    query_id query_id_count sum_requests_per_attack tempo_inicio
##       <int>          <int>                   <int> <dttm>
##  1    50265            618                    1283 2020-12-18 04:26:58
##  2    28826            145                     167 2021-03-01 10:34:11
##  3     4218             98                     110 2020-10-30 18:46:37
##  4     1337             74                      79 2020-10-30 02:55:07
##  5    44557             61                      68 2020-11-26 11:07:27
##  6    64206             57                      59 2021-02-05 13:23:20
##  7      256             43                     417 2021-01-19 02:50:02
##  8    16028             40                    3049 2020-11-10 02:29:52
##  9        0             31                     216 2020-11-03 07:26:10
## 10    19205             18                      74 2020-11-19 09:44:27
## # ... with 3 more variables: tempo_final <dttm>, tempo_diff_secs <dbl>,
## #   tempo_diff <drtn>
```

- Nada chamou a atenção

```
#N = 10


#data_split_year_period = data %>%
#  group_split(year_period)


#period_query_id_qname = data.frame()
#for (i in c(1:length(data_split_year_period))) {
#  query_id_qname_frequency = data_split_year_period[[i]] %>%
#    group_by(qname, qtype) %>%
#    summarise(tempo_inicio=min(tempo_inicio_cast), tempo_final=max(tempo_final_cast), sum_requests_per
#    mutate(tempo_diff_secs = as.numeric(tempo_final - tempo_inicio, units="secs"), tempo_diff = tempo_
#    arrange(desc(tempo_diff_secs))
#
#  period_query_id_qname = rbind(period_query_id_qname, head(query_id_qname_frequency, N))
#}
```

```
data %>%
  group_by(year_period, qtype) %>%
  summarise(sum_grouped_year_period_qtype = n()) %>%
  group_by(year_period) %>%
  mutate(sum_qtype_year_period = sum(sum_grouped_year_period_qtype), qtype_percentage = ((sum_grouped_y
```

```
  arrange(desc(qtype_percentage)) %>%
  head(10)
```

Registros separados por trimestre

```
## `summarise()` has grouped output by 'year_period'. You can override using the
## `.groups` argument.
```

```
## # A tibble: 10 x 5
## # Groups:   year_period [6]
##    year_period qtype sum_grouped_year_period_~ sum_qtype_year_~ qtype_percentage
##          <int> <chr>                     <int>            <int>            <dbl>
##  1       20204 ANY                      122840           136983             89.7
##  2       20211 ANY                      162599           213052             76.3
##  3       20221 ANY                        6934            11595             59.8
##  4       20212 ANY                       23182            39611             58.5
##  5       20213 A                         30519            53934             56.6
##  6       20214 A                         47906            98317             48.7
##  7       20214 ANY                       39673            98317             40.4
##  8       20221 A                          3826            11595             33.0
##  9       20212 A                         12326            39611             31.1
## 10       20211 A                         38499           213052             18.1
```

- Agrupa os dados por (qname, qtype, year_period) para calcular por trimestre a longevidade dos registros com o mesmo QNAME+QTYPE
  - OBS.: Inicialmente eu iria verificar a longevidade, mas não faz sentido então separar por trimestre para verificar o quanto um qname se manteve ativo dentro do trimestre, correto? @Obelheiro @Thiago

```
data_year_period = data %>%
  group_by(qname, qtype, year_period) %>%
  summarise(tempo_inicio=min(tempo_inicio_cast), tempo_final=max(tempo_final_cast), sum_requests_per_at
  mutate(year_period=as.factor(year_period), tempo_diff_secs = as.numeric(tempo_final - tempo_inicio, u
  arrange(desc(tempo_diff_secs))
```

```
## `summarise()` has grouped output by 'qname', 'qtype'. You can override using
## the `.groups` argument.
```

- Agrupa somente pelo trimestre e o QTYPE para calcular quantos qnames diferentes existem em cada QTYPE

```
data_year_period_qtype_quantity = data_year_period %>%
  ungroup() %>%
  group_by(year_period, qtype) %>%
  summarise(qtype_quantity = n())
```

```
## `summarise()` has grouped output by 'year_period'. You can override using the
## `.groups` argument.
```

- Calcular a porcentagem da quantidade QTYPE

```
data_year_period_qtype_quantity_percentage = data_year_period_qtype_quantity %>%
  group_by(year_period) %>%
  mutate(sum_qtype_quantity_year_period = sum(qtype_quantity), qtype_year_period_quantity_percentage=((
```

```
data_year_period_qtype_quantity_percentage %>%
  filter(qtype_year_period_quantity_percentage > 1) %>%
  ggplot( aes(x=year_period, y=qtype_year_period_quantity_percentage, fill=qtype)) +
    geom_bar(stat="identity", width = 0.55) +
    geom_text(aes(label = paste(round(qtype_year_period_quantity_percentage, 2), "%")), position = posi
    scale_fill_viridis(discrete=TRUE, direction = -1) +
    ylab("Porcentagem de QNAMES diferentes no trimestre") +
    xlab("Trimestre") +
    ggtitle("Quantidade de QNAMES diferentes em cada QTYPE no trimestre")
```

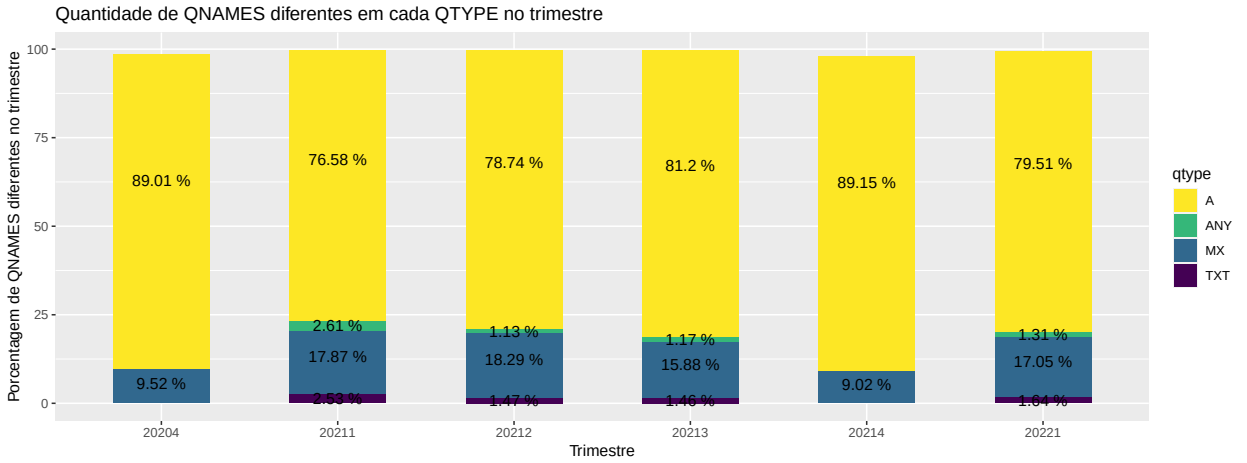

- Isso mostra que o QTYPE “A” tem uma grande quantidade de ataques com QNAMES distintos em cada trimestre